



Mesterséges Intelligencia

LGBIN0851

A mesterséges intelligencia szerepe a hiperspektrális képelemzésben

Gráczol Benedek Péter

CX77QX

Győr, 2018/19/1.

Tartalomjegyzék

1 Bevezetés	1
2 A hiperspektrális képelemzés folyamata	2
2.1. A hiperspektrális képalkotás	2
2.1.1. A hiperspektrális képalkotás alapjai	2
2.1.2. A hiperspektrális képalkotó eszközökről	4
2.2. A hiperspektrális adatok feldolgozása	5
2.2.1. A hiperspektrális adatkocka	5
2.2.2. Általános problémák a hiperspektrális képfeldolgozásban	6
2.2.3 A hiperspektrális képfeldolgozás klasszikus módszerei	7
3 Mesterséges intelligencia (MI) módszerek a hiperspektrális képelemzésben	9
3.1 Alkalmazott MI módszerek	9
3.2. Mesterséges neurális hálózatok (artificial neural networks)	9
3.2.1. A módszer ismertetése	9
3.2.2. A konvolúciós neurális hálózat szerepe a hiperspektrális képelemzésben	10
3.3. A tartóvektor-gép (support vector machine)	11
3.3.1 A módszer ismertetése	11
3.3.2 Az SVM szerepe a hiperspektrális képelemzésben	13
3.4. A fuzzy klaszterezés (fuzzy clustering)	15
3.4.1. A módszer ismertetése	15
3.4.2. A fuzzy klaszterezés szerepe a hiperspektrális képelemzésben	15
4 Összefoglalás és konklúzió	17
5 Felhasznált irodalom	18

1 Bevezetés

A hiperspektrális képfeldolgozás a 80-as évektől kezdődően, olyan távérzékeléses technológiákban valósult meg, melyek elsődleges célja a világűr objektumainak, különösképpen a bolygók felszíni jellemzőinek feltérképezésre irányult. Később a kutatások kiterjedtek a földfelszín geológiai és biológiai jellemzőinek alaposabb tudományos megismerésére is. Manapság pedig olyan alkalmazási területekről beszélhetünk a hiperspektrális képelemzéssel kapcsolatban, mint a növényeknél a betegségek diagnosztikája és a fenofázisok meghatározása távérzékeléses vagy laboratóriumi körülmények között. A technológia ugyanakkor jelen van és határozott fejlődést mutat az orvostudományban, a haditechnikában, de például a régészet objektumfelismerő rendszereit is hatékonyabbá teszi.

A hiperspektrális képfeldolgozás során az elektromágneses spektrum olyan tartományai is érzékelhetővé válnak, amelyek a hagyományos képalkotó megoldások esetében nem lehetségesek. A hiperspektrális képalkotó eszközök szenzorjai és érzékelési technológiái a látható fény tartományán túl, az ultraibolya illetve a kisebb energiájú infravörös tartományból is képesek információkat nyerni. A hiperspektrális képelemzés esetében ugyanakkor a látható fényt a klasszikus megoldásokkal szemben jóval részletesebb spektrumon dolgozzák fel. Ebből következően lényegesen nagyobb a kinyerhető adatok száma, mint más RGB-ben vizsgáló hagyományos képalkotók vagy a már több spektrum sávban is érzékelni képes multispektrális eljárások esetében. Az adatok számítógépes feldolgozásakor, a hiperspektrális kép ábrázolására egy háromdimenziós adatkocka, az ún. hiperspektrális kocka szolgál.

A nagy mennyiségű digitálisan feldolgozandó adat, ami objektumok vagy egy-egy képen felismerhető folyamat (pl. biológiai, földtani folyamat) azonosításához szükséges, a spektrumkönyvtár adatkészletére támaszkodik. Ebből következően tehát, az is fontos hogy a spektrumkönyvtár bőséggel tartalmazzon adatokat, információkat a kutatás anyagára vonatkozóan. A dolgozatban az is látható lesz, hogy a spektrumkönyvtár, azokat a hiperspektrális módszerekkel feldolgozott spektrumokat foglalja magában, amelyek az objektumok felismeréséhez szükséges alapvető információkat tartalmazzák. A hiperspektrális képelemzés képpontonként akár több száz hullámsávban képes megjeleníteni a különböző spektrumokat. Mindezzel óriási mennyiségű adat keletkezik, melyek hatékony kezelésére, tudományos igényű kiértékelésére az egyszerűbb elemzéseket végző algoritmusok, szoftverek már nem nyújtanak megfelelő támogatást. A mesterséges intelligencia megoldásainak alkalmazása tehát nem csak indokolt, hanem szükséges is ezen a területen.

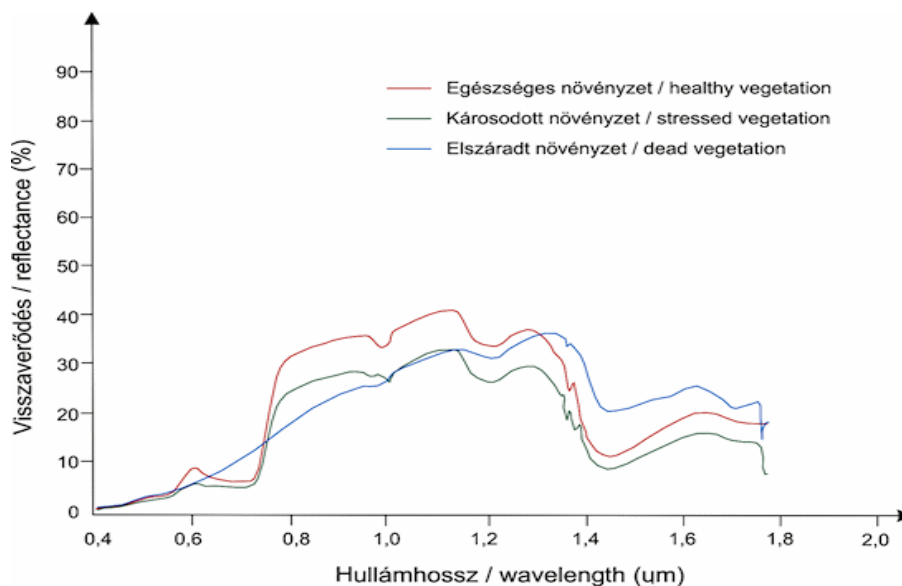
Dolgozatom célja, hogy bemutassam a hiperspektrális képelemzés folyamatát, tisztázva néhány alapfogalmat is, melyek ismerete még a tárgy nagy vonalakban való bemutatásához is elengedhetetlen. A képalkotó folyamatok bemutatása után sort kerítek a képalkotó eszközök rövid bemutatására is. Ezután kerül sorra azon adatfeldolgozási problémák ismertetése, melyek hatékonyabb, a mesterséges intelligencia területén alkalmazott módszerek használatát igénylik. A dolgozat második része pedig erre alapozva, azokat a leggyakrabban használt MI módszereket veszi sorra, amelyek a hiperspektrális képfeldolgozás folyamatában szerepet játszanak. Ennek megfelelően a következő módszerek, így a mesterséges neurális hálózatok (ANN: artificial neural networks), és annak egy változata a konvolúciós neurális hálózat, másodikként a Tartóvektor-gép (SVM: support vector machine), és a fuzzy klaszterezés, fuzzy c-közép klaszterezés lényegi bemutatására kerül sor.

2 A hiperspektrális képelemzés folyamata

2.1. A hiperspektrális képalkotás

2.1.1. A hiperspektrális képalkotás alapjai

A hiperspektrális képelemzés során egy adott felbontású kép, képpontonként való kiértékelése történik úgy, hogy minden egyes képpont alapján egy-egy spektrum felvételezésre kerül. Ezek a spektrumok, melyek objektumok leírására alkalmasak, a képalkotó eszközöktől is függően, néhány tíz, de akár több száz különböző hullámhosszú spektrum sávra, csatornára bonthatók. A spektrum sávok pedig aszerint oszthatók, hogy azok egy adott hullámhosszon milyen mértékű fényvisszaverő képességgel (reflektancia) rendelkeznek.



1.ábra: Növényzet különböző állapotainak spektruma

Forrás:

https://www.tankonyvtar.hu/hu/tartalom/tamop425/0033_SCORM_MFGGT218/sco_02_02.htm (Megtekintés napja: 2018.09.29.)

A hiperspektrális fogalmát Alexander F.H. Goetz planetáris geológus alkotta meg, és olyan távérzékeléses megoldást értett alatta, mely alkalmazásával az égitestek, majd -manapság már egyre gyakrabban- a föld felszínének feltérképezésére használnak. Mindez pedig a bolygók vagy a föld felszínéről visszaverődő napsugarak spektrális elemzésével történik, a különböző anyagok spektrumának mérési eredményei szerint. Goetz definíciója kimondja, hogy **„hiperspektrális képalkotásnak nevezzük azt az adatgyűjtési technikát, amikor (a felszínről) több száz (csatornán) regisztrált képet gyűjtünk egymással érintkező, spektrális sávban, úgy, hogy minden pixel radiancia spektrumát tudjuk levezetni.”**[1] A definícióból tehát láthatjuk, hogy nem csak arról van szó, hogy a hiperspektrális módszerekkel akár több száz csatornán vagy sávon keresztül felvételezhetünk, hanem hogy ezek a csatornák egymással összefüggő, azaz folyamatos hullámhossz tartományokat alkotnak. A hiperspektrális képalkotással kapcsolatban ezzel megállapítható, hogy **folytonos színekkel dolgozik.**[1]

A hullámsávok, csatornák számának megállapításával kapcsolatban vannak eltérő elgondolások, ami a képalkotó technológiák közti különbségek mellett a különböző tudományos megközelítéseknek is betudható. Egészen a 10 körüli sávától a több százas nagyságrendig, különböző elgondolások vannak a hiperspektrális képalkotás során vizsgált

hullámsávok számára vonatkozóan. Az Európai Unió Tanácsának egy 2003.évi belső rendelete (149/2003/EK), amely a távérzékeléses képfelvételzésre vonatkozóan a csatornaszám alapján hozott létre kategóriákat, **a hiperspektrális felvételeket a 21 db vagy ennél több csatornára** bontható spektrumok szerint sorolta be. A hiperspektrális mellett a kisebb sávmennyiségben felvételező technikákat is felsorolja.[2]

1. táblázat: a távérzékeléses felvételek az EU Tanácsa szerinti besorolása

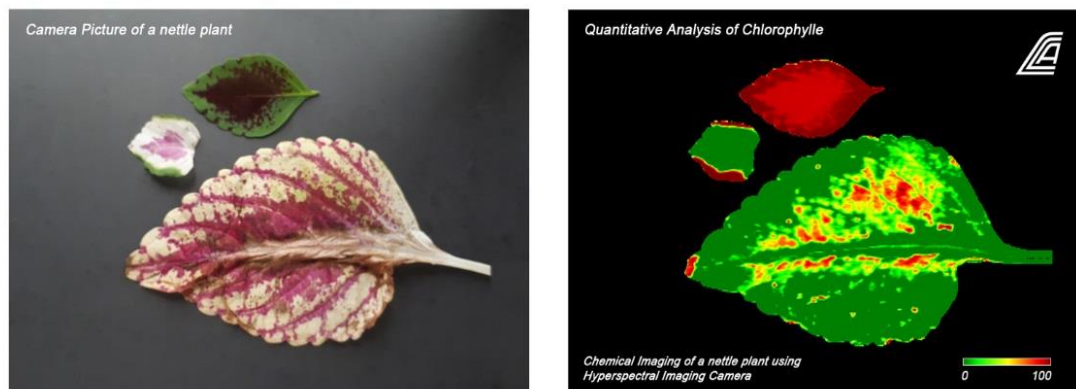
Távérzékeléses technológia	Csatorna/sáv (db)
Pánkromatikus kép	1
Színes kép (RGB)	3
Multispektrális kép	4-20
Hiperspektrális kép	21 -

Amíg a klasszikus képalkotók, mint például egy átlagos kereskedelembe kapható fényképezőgép vagy egy okos eszközön található beépített kamera csak három hullámsávot (RGB) használ a képalkotás során, addig a hiperspektrális szenzorok ennek a többszörösét képesek érzékelni. A hiperspektrális képelemzés is a látható fény tartományában felvételez, de a hagyományos képalkotó technikákhoz képest jelentősen nagyobb részletességgel képes azt csatornákra bontva megjeleníteni. Ugyanakkor a hiperspektrális módszerekkel való megjelenítés a látható fény érzékelésén túl, kiterjed az ibolyántúli és az infravörös tartományra is. A látható fény tartománya az elektromágneses spektrumon a megközelítőleg 400 nm hullámhossztól a kisebb energiájú, de nagyobb hullámhosszú infravörös tartományig terjed. A hiperspektrális technológia az infravörös tartományba lépve, a közeli infravörös (NIR) képes a spektrum sávok megjelenítésére, ahol már hosszabb 900-1700 nm hullámokról beszélhetünk. A spektrum ilyen mértékű kiszélesítésével tehát, a hiperspektrális képalkotás a látható fény tulajdonságai, - például reflektanciája (visszaverődése) mellett - a szabad szemmel nem érzékelhető közeget is elemezni tudja. A fény reflektanciája tulajdonképpen a fény visszaverődési mutatója, amely azt mutatja meg, hogy adott intenzitású fény milyen mértékben verődik vissza az adott fizikai felületről. Magát a fény intenzitását, a reflektancián kívül, a fényelnyelés (abszorpció) és a fényáthaladás (transzmisszió) szempontjából is figyelembe kell venni, vagyis ez a három mennyiség adja a besugárzó fény intenzitását, amelyet I_0 -val jelölünk.[3]

$$I_0 = I_T + I_A + I_R \quad (1)$$

Az pedig, hogy a fényintenzitás melyik paraméterére koncentrálni elemezzük a hiperspektrális technológiákkal készült képet, leginkább a kutatási terület vagy általában véve a vizsgálat célja határozza meg. A hiperspektrális távérzékelést alkalmazó területeken, ilyen módon a planetáris geológiában, a földrajztudományokban, az agrártudományokban és a környezetvédelemben és bizonyos laboratóriumi kutatásokban a felszíni fényvisszaverődés alapján határozzák meg az objektumokat, jelenségeket. A növények biológiai vizsgálata során, például egy levél hiperspektrális felvételezésekor, az egyes hullámhosszokon detektálható reflektanciákat veszik figyelembe. Az analitikai vizsgálatoknál ezeket ún. monokromatikus fényeknek nevezik, és ezeket a fény komponensekre való bontásával teszik megfigyelhetővé.[3] Azonban az objektumokat és tulajdonságaikat leíró spektrális jellemzők

egyediségének meghatározása a reflektanciából kiszámítható abszorpcióval teljes, ami azt jelenti hogy, *a hiperspektrális szenzorok egy-egy pixel felvételezésekor képesek a spektrumokon egyedi mintázatokat felismerni, a fényvisszaverő és fényelnyelő tulajdonságaik alapján.*[3]



2. ábra: Levélvizsgálat hiperspektrális kamerával

Forrás: <https://www.lla-instruments.com/compact-hyperspectral-scanner.html> (Megtekintés napja: 2018.09.29.)

2.1.2. A hiperspektrális képalkotó eszközökről

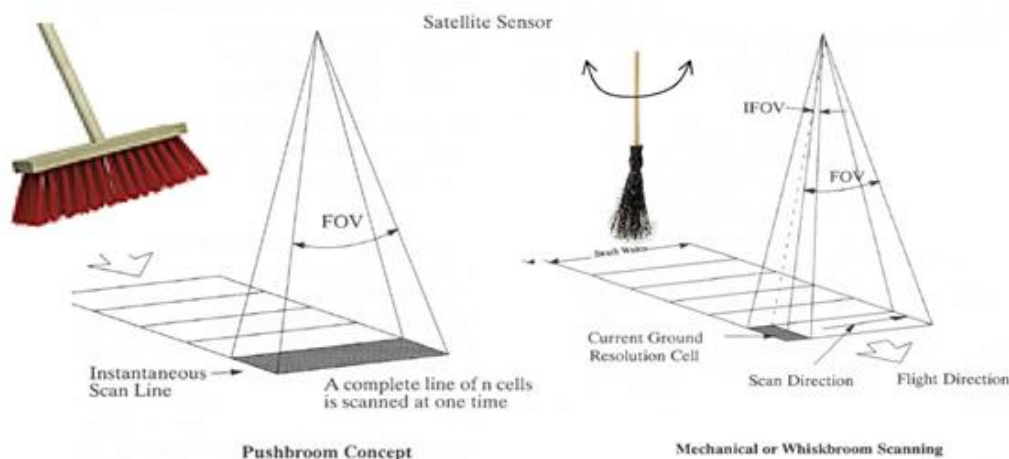
A hiperspektrális képalkotó eszközök közül elsőként a távérzékeléses érzékelőket érdemes megemlíteni. A hiperspektrális képelemzés klasszikus alkalmazási területe ugyanis az égitestek és a földfelszín geológiai tulajdonságainak elemzése. Az elektromágneses hullámok érzékelését végző eszközök a szenzorok. A szenzorokat osztályozhatjuk a sugárzás hullámhossza (látható fény, infravörös), a *szenzor energia forrása* (aktív, passzív), a *visszavert sugárzás detektálása* (analóg vagy digitális) és a *hordozó eszköz* (műholdas, földi, légi szenzorok) alapján.[4] A különböző hiperspektrális szenzorok tehát más-más hullámhossz intervallumokon és spektrális csatornaszámmal képesek érzékelni a felszíni tárgyakról visszaverődő sugárzást.

2. táblázat: légi érzékelők tulajdonságai [4]

Szenzor	Hozzáférhetőség	Csatornák száma	Hullámhossz(nm)
AAHIS	1994	288	432-832
AVIRIS	1987	224	400-2450
DAIS 7915	1994	79	498-12300
SASI	2002	160	850-2450

A műholdas érzékelők és a légi szenzorok mellett egyre elterjedtebb a drónok alkalmazása is. A drónokat jellemző módon az agráriumban, a precíziós mezőgazdaságban használják, ahol olyan feladatokat látnak el, mint a termőtalaj típusainak felismerése és a növényfajok, kultúrák víz-, nitrogén- és tápanyag ellátottsági szintjeinek a megállapítása. A drónok az ilyen típusú problémamegoldásban rugalmasabb alternatívát jelentenek a klasszikus műholdak vagy terepi spektrométerekhez képest. A drónokra szerelt szenzorok is képesek hiperspektrális felvételekre, és akár a látható és közeli-infravörös (VNIR: visible and near-infrared, 0,4-1 μm) vagy a rövidhullámú infravörös (SWIR: short-wave infrared, 1-2,5 μm) tartományokra is

kiterjedhet az érzékelési hatókörük.[5] A drónok vagy más légi képalkotók esetében természetesen a felvételezés magassága is fontos kérdés, ami nagyban függhet a céltárgyak azonosíthatósági feltételeitől. A távérzékeléses szenzorok esetében nem csak a képalkotó magassága, hanem a letapogatók (letapogató sávérzékelők) is fontos szerepet töltenek be a felvételezés folyamatában, így beszélhetünk kereszt (whisk-broom) és hosszirányú (push-broom) letapogatókról. Az alábbi ábrán jól látható, hogy a keresztirányú letapogató a felvételezéskor forgómozgással változtatja a pillanatnyi látószögét (IFOV: instantaneous field of view), míg a hosszirányú a szenzor haladási irányával merőlegesen végzi a felvételezést.



3.ábra: A hossz- (push-broom) és keresztirányú (whisk-broom) letapogatók

Forrás:

https://www.tankonyvtar.hu/en/tartalom/tamop425/0032_terinformatika/ch05.html

(Megtekintés napja: 2018.09.29.)

Megjegyzendő, hogy az érzékelhető spektrális sávok száma, a frekvencia tartományok szélessége és a zajszűrés is lényeges tulajdonság ezeknél a szenzoroknál.

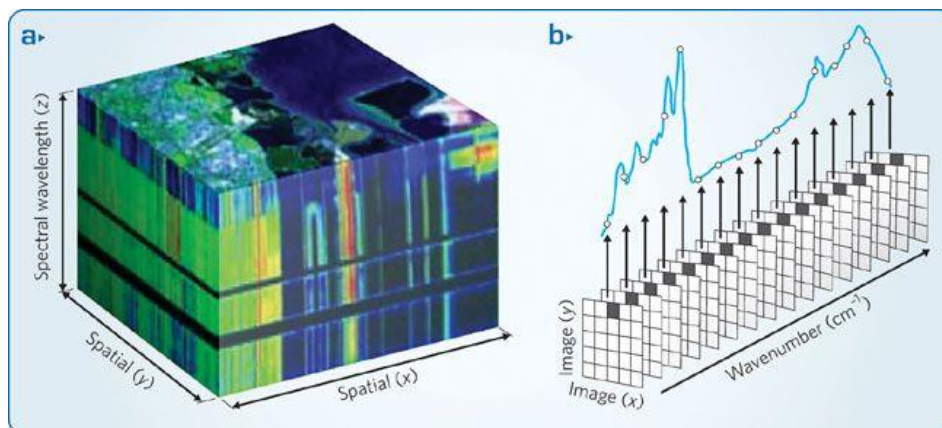
Végül megemlíthetők még a laboratóriumokban, kórházakban használt hiperspektrális képalkotók, vagy azok a kereskedelmi forgalomban kapható kézi kamerák is, amelyekkel hiperspektrális képeket készíthetünk. A jövőben amennyiben a piaci feltételek is kedvezők lesznek, a mobil eszközökbe építve is megjelenhetnek ezek a technológiák. A legnagyobb akadálya a hiperspektrális eszközök szélesebb körben való elterjedésének a magas ár és az a tény, hogy egyelőre jellemzően tudományos és speciális szakterületeken alkalmazzák azokat. Ezért olyan új trendek kialakulására, új felhasználási területek megjelenésére is szükség volna, ahol nagyobb volumenben lehetne értékesíteni ezeket a készülékeket.

2.2. A hiperspektrális adatok feldolgozása

2.2.1. A hiperspektrális adatkocka

Egy megfelelően nagy felbontású kép esetében, tekintve hogy képpontonként akár több száz hullámsávra is képződhetnek digitális adatok, akár több száz millió, de több milliárd adatról is beszélhetünk. Ahogy azt majd későbbi fejezetekben látni fogjuk, ilyen mennyiségű adat, digitális információ feldolgozásához, a köztük levő hipotetikus vagy valós összefüggések meghatározásához a klasszikus képfeldolgozó módszerekhez képest jóval fejlettebb, a mesterséges intelligencia területén alkalmazott tanuló algoritmusok szükségesek. A hiperspektrális képalkotás során létrejövő adatokat egy háromdimenziós, ún. adat kocka vagy hiperspektrális adatkocka szemlélteti, melynek képét három vektorral adhatjuk meg. Ezek

közül kettő, melyek alapján megismerhető a kép felbontása, így a képpontok száma (x,y) a térbeli, míg a harmadik a spektrális dimenziót mutatja meg. A spektrális dimenzió a spektrum sávok fényvisszaverési tulajdonságait reprezentálja. Ezt λ -val vagy z -vel szokás jelölni. Az (x,y) vektorokkal a kép kétdimenziós, míg az (x,y) -ra merőleges λ vektorral kiegészítve a kép háromdimenziós ábrázolását kapjuk meg.



4.ábra: Hiperspektrális adatkocka a térbeli (x,y) és a spektrális (z) dimenziókkal

Forrás: <https://www.nature.com/articles/nphoton.2009.205> (Megtekintés napja: 2018.09.29.)

Az ábrán is jól látszik, hogy a képpontokként felvételezhető hullámsávok olyan nagyságrendű információt tartalmaznak, melyek a digitális adatfeldolgozás során csak több-dimenziós tömbökként implementálhatók. Amennyiben a sorok száma n_1 és az oszlopoké n_2 , valamint a λ egyenesen N -számú csatornát különböztetünk meg, akkor az adatkocka adatainak száma: $n_1 \times n_2 \times N$. [1]

2.2.2 Általános problémák a hiperspektrális képfeldolgozásban

A spektrumkönyvtárak tartalmazzák azokat a hiperspektrális szenzorokkal felvételezett spektrumokat, amelyek a tárgyak beazonosításához szükséges információkat tartalmazzák. Akár egy képponton felvett spektrum is azonosíthat valamilyen objektumot, de leggyakrabban több spektrum felvétele szükséges a minél pontosabb meghatározáshoz. Vannak olyan esetek is, amikor egy képponton több egymástól különböző objektum is felvételezésre kerül, ilyenkor a spektrumsávok elemzése segíti a felismerést.

A hiperspektrális adatok feldolgozása során **leggyakrabban előforduló problémák, az adatközméretből és a redundanciából** adódhatnak. [6] Az adatközméretből következő problémák inkább a klasszikus vagy multispektrális képfeldolgozással, mintsem a rendelkezésre álló számítógépes tároló kapacitással összefüggésben foghatók fel, ugyanis manapság akár terrabájtokat kitevő adatközmennyiségek tárolása sem jelenthet kihívást. Például egy felvétel az AVIRIS légi szenzorral, képpontként 224 spektrum sávban érzékel, melyek tárolásához egyenként 10 bit szükséges. Képpontként tehát ebben az esetben 2240 bitről van szó. [6]

Ami már komolyabb kihívás elé állítja a hiperspektrális képek elemzőit, az az adatok redundanciája. A hiperspektrális képek elemzésénél ugyanis jellemzően több 10-szer nagyobb adat keletkezik, mint például egy multispektrális kép esetében. Ez azonban nem jelent 20-szor vagy 30-szor annyi információt. Gyakran előfordul ugyanis, hogy bizonyos adatok már nem nyújtanak többletinformációt a céltárggyal kapcsolatban, vagyis a vizsgálat számára redundáns adatokká válnak. Az adatok redundanciája is kétféle lehet, egyrészt **beszélhetünk térbeli másrészt spektrális redundanciáról**. A térbeli redundancia esetében arról van szó, hogy egy képpont és szomszédos képpontja, vagy képpontjai egymáshoz hasonló spektrummal rendelkeznek. Ilyenkor kezdeti megoldásként hasznos lehet a szegmentálás, a


hasonló spektrális jellemzők alapján való csoportosítás. A spektrális redundancia pedig olyankor állapítható meg, amikor egy spektrális sáv alapján megjósolhatók más spektrális sávok tulajdonságai is.[6]

Az adatok méretéből következően a tárolás okozza talán a legkisebb problémát, de a térbeli és spektrális adatok redundanciája már nagyobb kihívást jelent. Van ugyanakkor egy másik jelenség is, aminek szintén az adatmennyiség van a háttérben. A **Hughes-jelenség** a spektrális dimenziók számosságából adódik. A hiperspektrális képeket feldolgozó tanuló algoritmusoknak nagy mintaszámmal, tanuló adattal kell dolgozniuk. A feldolgozandó spektrális sávok növekedésével, egyre több tanuló mintára van szükség a minél pontosabb osztályozás érdekében. Mivel mindig csak korlátozott számú tanuló minta áll rendelkezésre, ezért az újabb spektrális sávok bevonása eredménytelen lesz az osztályozás szempontjából. A hagyományos osztályozási módszerek nem hatékonyak a probléma megoldásában. A dolgozat második részében egy olyan módszer is szerepel, ami képes a jelenség hatását kivédeni.[6]

2.2.3 A hiperspektrális képfeldolgozás klasszikus módszerei

Arról már korábban is szó volt, hogy a hiperspektrális képelemzés során keletkező nagyszámú adatok nem feltétlenül a tárolás szempontjából okoznak nehézségeket. Az adatok számosságával kapcsolatban redundáns mivoltuk is szóba került, ugyanakkor az egyes kutatási területek céljai eltérők lehetnek abban a tekintetben is, hogy milyen pontossággal kívánják a képképző eszközök segítségével kapott spektrumokat kiértékelni. Hasonló esetekben ugyanis a nagy számú adat kezelése már problémás lehet. Ahhoz, hogy a képelemzés elvárt eredményességgel teljesítse a kutatás vagy vizsgálat célkitűzéseit, a rendelkezésre álló számítási kapacitás mellett a képfeldolgozó algoritmusok megfelelő kiválasztása is elengedhetetlen. Az alábbiakban a hiperspektrális képfeldolgozásban használt leggyakoribb klasszikus megoldásokról fogok röviden szót ejteni.

Azok a képfeldolgozó megközelítések, melyek a **spektrális tulajdonságok összehasonlítása** alapján osztályozzák az egyes képpontokat, külön-külön egymástól függetlenül felvételeznek és rögzítenek információkat. Az elemzés során olyan spektrális tulajdonságokról van szó, mint a fényvisszaverési képesség (reflektancia) és a fényelnyelés (abszorpció). Ezen paraméterek ismeretéből körvonalazható a spektrum alakja.



5. ábra: Fényelnyelés (abszorpció)

Forrás: http://people.inf.elte.hu/fekete/tamop_2010/Szakdolgozat_diploma/Hamori_A_diplomamunka.pdf (Megtekintés napja: 2018.09.29.)

Az ábrán látható fényelnyelés is többféle szempontból vizsgálható, így például mélysége és jellegzetessége szerint. A kontinuum pedig azt mutatja meg, hogy hol helyezkedik el a spektrumalak felső határa. Nagy vonalakban bemutatva ezen spektrális tulajdonságok kiértékelésére van szükség, amikor a hiperspektrális képek adatainak feldolgozása történik.

Általánosan alkalmazott eljárási mód, hogy ezeket a spektrumokat és az őket leíró jellemzőket egy referencia adatbázisban tároljuk, és a képfeldolgozás folyamatában felhasználjuk. Ezeket az adatbázisokat nevezzük **spektrumkönyvtár**aknak is. A spektrumkönyvtár információinak bővítése történhet laboratóriumi körülmények között, a különböző anyagok, vizsgálati tárgyak spektrális jellegzetességeinek felvételezésével, vagy normál működés során öntanuló algoritmusok segítségével. Klasszikus megoldásként az előbbire példa a kalibráció, amikor valamilyen összehasonlító módszer szerint történik a felvételen szereplő objektumok detektálása. A teljes azonosság a külső hatások (pl. zajok, sugárzási szóródás, idegen tárgyak) miatt valószínűtlen, de az adatbázisban szereplő mintázatok hasonlóság szerinti rangsorolása jól alkalmazható ezekben az esetekben. A sávonként történő reflektancia eltérés négyzetes közepének a kiszámítása például egy ilyen lehetséges megoldás.[6]

$$\|x - y\| = \sqrt{\sum_{k=1}^K (x_k - y_k)^2} \quad (2)$$

,ahol x és y a két összehasonlítandó spektrum, a K a spektrális sávok számát jelöli, míg az x_k az x spektrum, k -adik sávjában mért visszaverődés.[6]

A hiperspektrális képfeldolgozás megközelítései közé sorolhatók még olyan **statisztikai módszerek**, mint például a diszkriminancia analízis, logisztikus regresszió, klaszter-analízis vagy a legközelebbi szomszéd analízis (k -nearest neighbors), ugyanakkor klasszifikáció, osztályozás történhet még térbeli információk vagy blokkok alapján is.[6]

3 Mesterséges intelligencia (MI) módszerek a hiperspektrális képelemzésben

3.1 Alkalmazott MI módszerek


A következőkben olyan mesterséges intelligencia módszerek kerülnek bemutatásra, amelyeket a hiperspektrális képfeldolgozás során is alkalmaznak. A hiperspektrális képfeldolgozás során felmerülő leggyakoribb problémák, mint ahogy azokról már korábban szó esett, általánosságban a nagy mennyiségű adat feldolgozási igényéből adódik. Az adatok osztályozására, a redundancia csökkentésére hatékony megoldások kellenek. A spektrális sávok vagy csatornák, melyek képpontonként több száz-as számban is előfordulhatnak ilyen kihívás elé állítják ezeket a módszereket. A most következő megoldások hatékonyan végzik a több-dimenziós hiperspektrális adatok feldolgozását, ellenállnak a Hughes-jelenség hatásainak és a zajok szűrésére is alkalmasak.

Összesen három módszerről esik szó, rövid általánosabb ismertetésük és a tárgyalt területen való alkalmazásuk vonatkozásában. Először a mesterséges neurális hálózatokról lesz szó, és a témához kapcsolódó módszerként a konvolúciós mesterséges hálózat működési elvéről. Ez egy újabb megközelítése a hiperspektrális képfeldolgozásnak. Elterjedtebb és az osztályozási feladatokra meglehetősen hatékony megoldás a tartóvektor-gép módszer vagy SVM (support vector machine). Végül a fuzzy klaszterezés, pontosabban a fuzzy c-közép klaszterezés bemutatása következik, amely pedig a kevert képpontok kezelésében számít hatékony módszernek.

3.2. Mesterséges neurális hálózatok (artificial neural networks)

3.2.1. A módszer ismertetése

A mesterséges neurális hálózatok módszere a tanulási folyamatok biológiai hátterére alapozott szimuláció. A módszer alapegységét a mesterséges neuront az agyi biológiai folyamataiban részt vevő neuron mintájára dolgozták ki, ugyanakkor a mesterséges változat ennek nagymértékben leegyszerűsített modellje. A mesterséges neuronhálók legalább három, de általában több réteggel rendelkeznek. Az első réteg a **bemeneti (input)** adatokat, míg az utolsó a **kimeneteket (output)** reprezentálja. A kettő között legalább egy vagy több ún. **rejtett réteg** szerepelhet, melyek száma elsősorban a választott feladat komplexitásától függ. A rejtett rétegek feladata, hogy a hozzájuk tartozó neuronok a szomszédos rétegek neuronjaival kapcsolatot tartsanak fenn, információkat közöljenek számukra. A rejtett rétegek neuron száma és kapcsolódási tulajdonságaik változtatható, tanítható paraméterek. A neuronokat a bemenetek tulajdonságai szerint súlyozzák, melyek összegeit egy nem lineáris aktivációs függvény dolgozza fel. Az alábbi kép ezt a folyamatot ábrázolja.



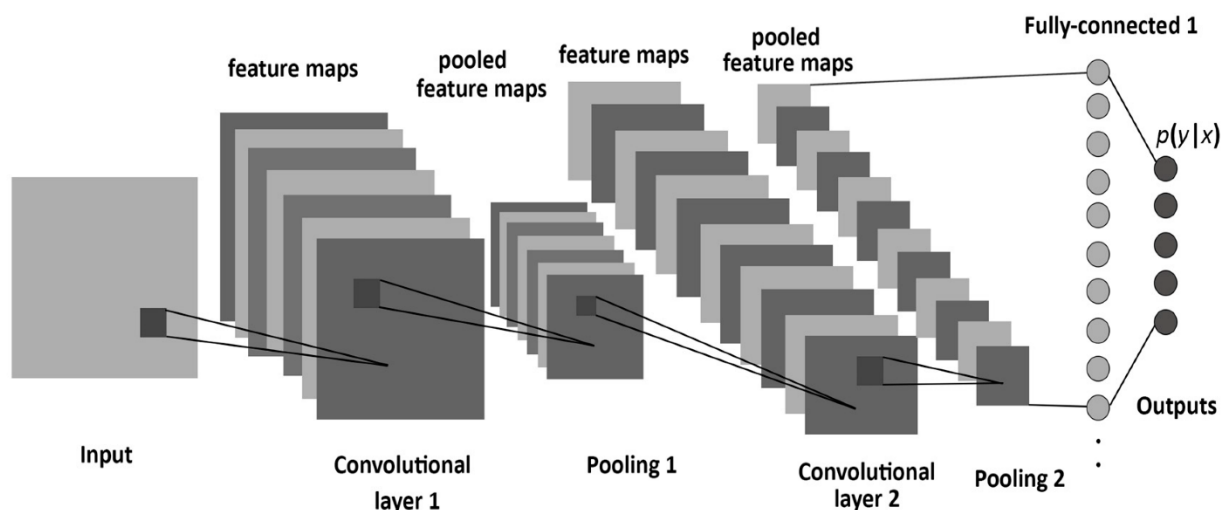
6.ábra: A mesterséges neurális hálózat működési modellje

Forrás: <https://naadispeaks.wordpress.com/2017/11/08/artificial-neural-networks-with-net-in-azure-ml-studio/> (Megtekintés napja: 2018.09.29.)

A mesterséges neurális hálózatok neuronjai a rétegeken keresztül és valamilyen súlyozás alapján kapcsolódnak egymáshoz, melyek értékeit a neuronok továbbítják egymásnak $i \rightarrow j$. Ebben a viszonyban tehát az i szülője j -nek és j leszármazottja i -nek. A súlyozást a w jelöli. A neurális hálózatok is többféleképpen differenciálhatók, például aszerint, hogy **a tanulási folyamatok felügyelvek** (supervised) vagy **nem felügyelvek** (unsupervised). Amikor a tanulási folyamat felügyelet alatt áll, akkor egy „tanító” beavatkozásától függ. Ilyen esetben, a tanító megadhat egy eredményt, ami a bemeneti adatok és a rejtett rétegek bizonyos neuronjainak súlyértékei alapján elvárható. Amennyiben a kimeneten megjelenő szám nem egyezik a várható eredménnyel, hiba történik. Ekkor az ún. **hibavisszaterjesztéses-algoritmus (backpropagation)** az eredmény számításban részt vevő neuronok súlyértékeit módosítja (tanítja) egészen addig, míg az a kívánt eredményt elfogadható mértékben meg nem közelíti. A mesterséges neurális hálózatok tanulási folyamata ilyen szempontból, tehát egy hibajavítási folyamatként képzelhető el, mely során a hibajavítás a rétegeken fokozatosan visszafelé haladva valósul meg.[7]

3.2.2. A konvolúciós neurális hálózat szerepe a hiperspektrális képelemzésben

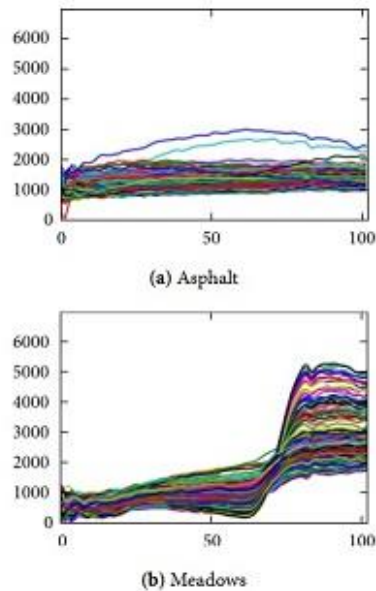
A mesterséges neurális hálózatok tanulási módszerei általában jól alkalmazhatók ott, ahol nagyszámú adat feldolgozására van szükség. Éppen ezért a hiperspektrális képelemzés területén is az egyik legnépszerűbb gépi tanulási módszerről van szó. A neurális hálózatok modelljeinek és algoritmusainak használata a hiperspektrális képelemzés területén újszerűnek mondható. A mesterséges neurális hálózatok módszerei közül a mély tanulási konvolúciós neurális hálózatok (továbbiakban CNN) az egyik leghatékonyabb megoldás. A CNN abban különbözik az általános neurális hálózattól, hogy a konvolúciós réteg neuronjai csak szórványosan kapcsolódnak a következő réteg neuronjaihoz. A CNN a neurális hálózatok előterjesztéses modelljét reprezentálja, mely több konvolúciós réteget foglal magában.[8]



7.ábra: A konvolúciós neurális hálózat réteges felépítése

Forrás: <https://www.mdpi.com/1099-4300/19/6/242> (Megtekintés napja: 2018.09.29.)

A képképzés során a legnagyobb kihívás az osztályokon belüli megjelenítés és az objektumok alakjának variációi. A modellben a több száz hiperspektrális sáv egy 2D grafikonon ábrázolható, amelyek egy-egy osztályt reprezentálnak. A következő példában a Paviai egyetem 9 osztályt különböztetett meg, ezek egy város és környezetének hiperspektrális felvételezése után a fákat, az aszfaltot, réteket, kavicsot, tisztásokat, tiszta talajt, bitument, téglákat, és árnyékokat reprezentálják.[8]



8.ábra: Az aszfalt és a rétek spektrális jellemzői osztályozás alapján


Forrás: <https://www.hindawi.com/journals/js/2015/258619/fig2/> (Megtekintés napja: 2018.09.29.)

A CNN felépítését tehát több rejtett réteg jellemzi, és különféle megközelítések leginkább abban különböznek, hogy az egyes rétegek miként valósulnak meg illetve a kapcsolatok mennyire tanítottak. A tanítható paraméterek, vonatkoznak akár hiperspektrális adatokra először egy kezdeti értéket vesznek fel egy meghatározott intervallumból. A tanulási folyamat pedig két lépésből áll, az **előterjesztésből (forward propagation)** és a **visszaterjesztésből (back propagation)**. Az előterjesztés a bemeneti adatok aktuális osztályozási eredményeit érvényes paraméterekkel látja el, a visszaterjesztéses eljárás pedig, ahogy korábban szó esett róla, a folyamatban részt vevő tanítható paramétereket visszaterjesztve módosítja, abból célból hogy az ellentmondás a kimeneti érték és az elvárt érték között a lehető legkisebb legyen.[8]

3.3. A tartóvektor-gép (support vector machine)

3.3.1 A módszer ismertetése


A tartóvektor-gép módszere (a továbbiakban SVM) a statisztikai tanulás elméletéből származik. A módszer jól alkalmazható több dimenziós adatok feldolgozásához, adatok osztályozáshoz és regresszió elemzéshez. Az SVM az adatok osztályozását hipersíkok segítségével végzi. Ezen hipersíkok alkalmazásával -végtelen sok hipersík lehetséges - különíthetők el az egymástól eltérő információkat hordozó adatok. A döntési határok a tanuló esetek egy részhalmazát reprezentálják, ezeket nevezzük tartóvektoroknak (support vector). Az adatok osztályozása során ki kell választani azt a hipersíkot, amelyik ezt a döntési határt fejezi ki. Mindez pedig aszerint történik, hogy melyik hipersík hogyan teljesít a teszteseteken. A nagyobb margójú döntési határok kevésbé befolyásolják az osztályozást, és korábban nem ismert esetek általánosításában jobban teljesítenek. [9]



9.ábra: Hipersíkok elválasztása két adattípus esetében

Forrás: <https://commons.wikimedia.org/w/index.php?curid=22877598> (Megtekintés napja: 2018.09.29.)

A maximális margójú hipersíkok úgy képezhetők, hogy egy olyan hipersíkot választunk ki, mely úgy különíti el egymástól az adattípusokat, hogy azok távolsága a hipersíktól egyforma legyen, de a többi lehetséges hipersíkhhoz képest a legnagyobb távolságot fejezze ki. Ezzel megadható az a maximális távolságú margó, ami a különböző adattípusokat elhatárolja a hipersíktól.[9]



10.ábra: Maximális margójú hipersíkok képzése

Forrás:

https://www.tankonyvtar.hu/hu/tartalom/tamop425/0046_adatbanyaszat/ch05s05.html
(Megtekintés napja: 2018.09.29.)

Az ábrán látható, hogy a két döntési határ B_1 és B_2 először is jól szétválasztja a tanulóeseteket különböző osztályokra. Továbbá párhuzamos hipersíkok meghúzásával megállapítható az is, hogy melyik döntési határ rendelkezik a nagyobb távolságú margóval. A párhuzamos síkokat tehát addig húzzuk, míg azok nem érintik a legközelebbi különböző típusú adatokat, esetünkben a négyzetet és a kört.[9]

Az SVM alapjai után fontos megismerni a módszer erősségét a kernel függvényeket, melyek a mintázat felismerésben töltenek be hasznos szerepet. A mintázat felismerés során az adatok olyan általános kapcsolatainak keresése történik, mint a klaszterezés, osztályozás és összefüggések az adathalmazban. A kernel módszer lényege, hogy a nem lineáris teret lineárisra transzformálja. A különböző SVM algoritmusok különböző kernel típusokat használnak attól függően, hogy milyen feladatot kell elvégezniük. Kép elemzésnél például a lineáris és a polinom kernel használható, az adatok ismeretének hiányában pedig az RBF (Gaussian radial basis function) lehet megoldás.[10]

3.3.2 Az SVM szerepe a hiperspektrális képelemzésben

Ahogy már az előző alfejezetben is szóba került, az SVM módszer kiválóan teljesít olyan esetekben, ahol nagy mennyiségű adat feldolgozására van szükség, ebből következően a hiperspektrális képfeldolgozás során is gyakran alkalmazott megoldás. A kernel alapú osztályozó módszerek népszerűek a hiperspektrális képelemzés területén is, mivel hatékonyan alkalmazhatók olyan feladatokra, ahol több dimenziós adatokkal és zajszűrővel kell dolgozni. Az SVM a több-dimenziós adatstruktúrákat hatékonyan kezelő, és ahogy az látható lesz a Hughes-jelenségnek is ellenálló módszernek tekinthető.[11]

A hiperspektrális képelemzésben a legnagyobb problémát a térbeli és spektrális adatok osztályozása jelenti. A térbeli-spektrális osztályozási módszerek erre a problémára nyújtanak megoldást. Általában ezen módszereknek három kategóriáját különböztethetjük meg, az első kategóriában a térbeli információ és a spektrális információ integrálása történik kompozit kernelek használatával. A térbeli tulajdonságok vizsgálatára többek között olyan algoritmusok állnak rendelkezésre, mint az EPF (edge-preserving filtering) és a EMPs (extended morphological profiles). A második kategóriában a térbeli és spektrális információk integrációját képszegmentáló algoritmusok végzik (hierarchikus szegmentáció, minimális feszítő fa, szuperpixel). A végső osztályleképezést szavazó algoritmusok felhasználásával, a pixel-wise osztályleképezés és a nem felügyelt szegmentáló osztályleképezés kombinálásával kapjuk meg. A harmadik kategóriában a két típusú információ csatlakozik az osztályozási folyamathoz, ami a MRF (Markov random field) modell felhasználásával történik.[10]

Egy másik ide vonatkozó probléma a Hughes-jelenség. A Hughes-jelenség a megnövekedett mintaszámok hatására következhet be. Egy a madridi Alcalá egyetemen elvégzett kísérlet alapján -14 illetve 30 spektrum sávval vizsgálva – az a következtetés vonható le, hogy a Hughes-jelenség nem befolyásolja az SVM módszer pontosságát. A kísérletben az Alcalá egyetem kampuszát felvételezték egy AHS (airborne hyperspectral scanner) távolsági szenzorral, mely a Spanyol Űrtechnológiai Intézet tulajdona. A felvétel 1300 méteres magasságban készült. A keresztirányú letapogató 2700 m, míg a hosszirányú 14 km, a felbontás megközelítőleg 3,5 méter. A szkennert 80 spektrális sávot képes érzékelni az elektromágneses tartomány skáláján. A 80 sávból elsősorban a zajok kiszűrése miatt, az első SVM mérésnél 14, a másodiknál 30 sávot vettek figyelembe. A kontroll esemény, mely kapcsán megfigyelhető a Hughes-jelenség egy klasszikus távolságmérésre használt algoritmus, a Mahalanobis modell volt. A teszt során Mahalanobis modellt hasonlították össze az SVM módszerrel. Az alábbi ábrán az látható, hogy a Mahalanobis modell esetében a Hughes-jelenség a 10. dimenziónál, 11% ROI-nál (region of interest), azaz a vizsgálati tartományt kitevő pixeleket 11%-ban tartalmazó osztályánál figyelhető meg.[11]

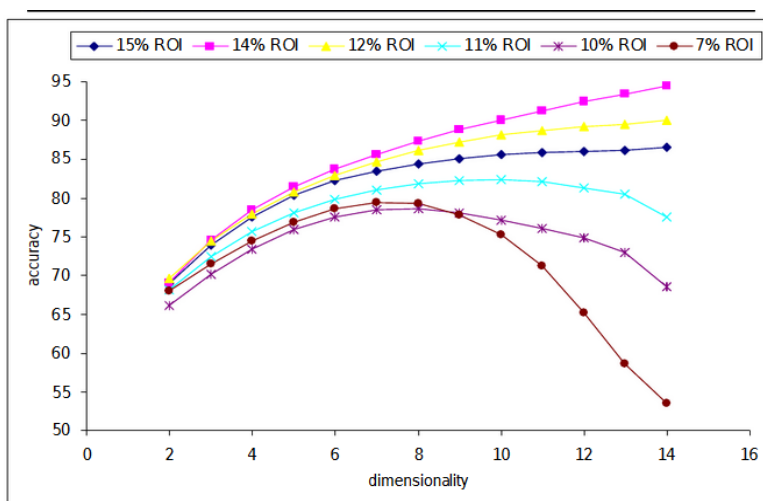


Figure 5. Accuracy of Mahalanobis classifier for different training sets.

11. ábra: A Mahalanobis osztályozó módszer pontossága különböző tanító mintákra

Forrás:

https://www.researchgate.net/publication/283485444_Consequences_of_the_Hughes_phenomenon_on_some_classification_Techniques (Megtekintés napja: 2018.09.29.)

A következő ábrákon az látszik, hogy az SVM módszer alkalmazása esetében a Hughes-jelenség nem figyelhető meg. A módszert a 14 spektrális csatorna esetében 5 tanító adatkészletre, míg 30 csatornánál két tanító adatkészletre tesztelték.[11]

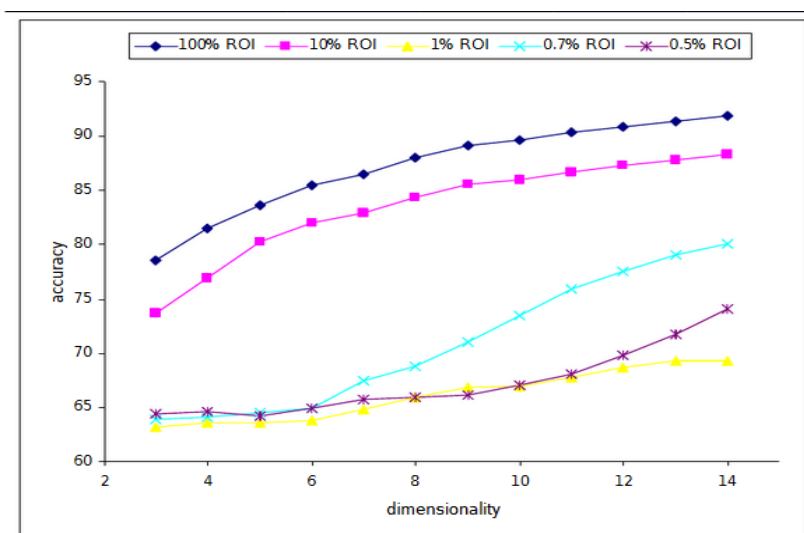


Figure 7. SVM apply to AHS with different training sets.

12. ábra: Az SVM módszer pontossága 14 spektrális sáv esetében különböző tanító mintákra

Forrás:

https://www.researchgate.net/publication/283485444_Consequences_of_the_Hughes_phenomenon_on_some_classification_Techniques (Megtekintés napja: 2018.09.29.)

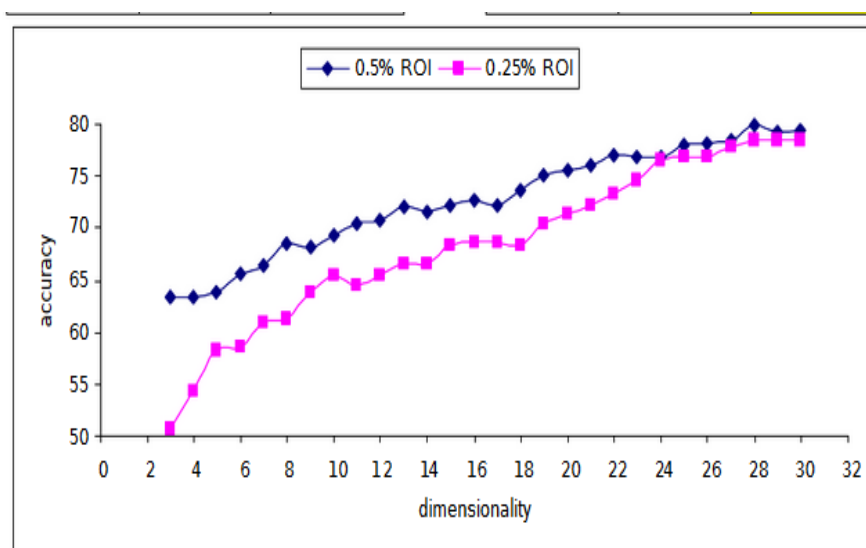


Figure 8. SVM with 30 bands

13.ábra: Az SVM módszer pontossága 30 spektrális sáv esetében különböző tanító mintákra

Forrás:

https://www.researchgate.net/publication/283485444_Consequences_of_the_Hughes_phenomenon_on_some_classification_Techniques (Megtekintés napja: 2018.09.29.)

3.4. A fuzzy klaszterezés (fuzzy clustering)

3.4.1. A módszer ismertetése

A fuzzy klaszterezés egy nem felügyelt tanulási módszer. Az eljárás során nagy mennyiségű adat csoportokra vagy klaszterekre bontása történik azzal a céllal, hogy a minél nagyobb mértékben hasonló, homogén adatok azonos klaszterekbe kerüljenek. Ezzel együtt a különböző klaszterekbe kerülő adatok a lehető legnagyobb mértékű eltéréseket mutatják. A módszer nem csak a -meghatározott feltételek szerint- hasonló adatok klaszterezésére szolgál, hanem emellett hatékonyan alkalmazható nagy mennyiségű önálló adat, kisebb csoportokba való tömörítésére is. A fuzzy klaszterezés tehát ezen a módon segíti az olyan rendszerek átláthatóságát, ahol nagy mennyiségű adat feldolgozására van szükség. A klaszterezés matematikai eljárásai távolságmérő függvényeket alkalmaznak, melyek ekvivalens műveletek a hasonlóságok megállapításakor is. Vagyis ezekben az esetekben, az adatok megmért különbözőségéből kikövetkeztethető az is, hogy azok milyen mértékben hasonlítanak. Az objektumokat pedig különféle tulajdonságok alapján, különféle klaszterekhez tartozó adatokkal határozhatjuk meg. Ebből következően tehát egy objektum a jellemzői alapján, különböző mértékben, de egyszerre több klaszterrel is összefüggésbe hozható. Az, hogy melyik objektum milyen mértékben tartozik egy adott klaszterhez egy 0 és 1 közötti értékkel adható meg. Elmondható tehát, hogy egy objektum, ha 0 mértékben is, de mindegyik klaszterhez hozzátartozik.[12]

3.4.2. A fuzzy klaszterezés szerepe a hiperspektrális képelemzésben

A fuzzy klaszterezés a hiperspektrális képek elemzésekor elsősorban a kevert képpontok esetében jöhet szóba, vagyis olyankor amikor egy képponton több objektum spektrumi is megfigyelhető. A módszer a képfeldolgozás során a képpontokat, mint bemeneti adatokat c osztályba sorolja, ahol c egy egész szám és az osztályok számára utal (fuzzy c -közép klaszterezés). Egy elem akár több osztályhoz is tartozhat. Az algoritmus kezdetben az

elemeket véletlenszerűen sorolja az osztályokba, majd az elemek csoportokba mozgatása egy iterációs eljárással történik a legkisebb négyzetes hiba függvény felhasználásával. A kevert képpontok esetében az elemek osztályokba sorolása nem egyértelmű, hanem azok részleges vagy többszörös tagsággal rendelkeznek az osztályokban. Amikor egy elem több osztályhoz is tartozhat, akkor gyenge osztályozásról beszélhetünk. Ilyenkor egy U mátrix elemeire vonatkozóan (U_{ik}) az kerül megállapításra, hogy a k -adik elem milyen mértékben tartozik i -edik osztályba. A mérték 0 és 1 közötti szám, és minden osztályba tartozik elem. A különböző osztályokba tartozás összege 1. Az osztályokba tartozás mértékét, ezzel az osztályok és elemek kapcsolatát a tagsági függvény fejezi ki. [6]

4 Összefoglalás és konklúzió

A hiperspektrális képelemzés alkalmazási területe eredetileg a távérzékeléses technológiák voltak. Később az orvostudomány, a mezőgazdaság, a hadtudomány és a régészet is felhasználta a hiperspektrális képalkotásban rejlő lehetőséget, nevezetesen azt, hogy a hagyományos képalkotókhoz képest jóval szélesebb spektrumtartományban is képes érzékelni. A technológia olyan tartományokat is vizsgál, ahol az emberi szemmel nem látható folyamatok zajlanak. Az orvostudományban például a bőrfelszín vizsgálatára, a haditechnikában különféle objektumok beazonosítására vagy a mezőgazdaságban a termőterület vízellátottságára, a növénybetegségek diagnosztikájára alkalmazható a hiperspektrális képelemzés. Az említett területeken ugyanakkor abban különbözik a hiperspektrális technológia felhasználása, hogy távérzékelő szenzorokat vagy kisebb kézi eszközöket használnak laboratóriumi körülmények között. Ez utóbbi esetekben például a leveleken zajló kóros elváltozások, tápanyagigények elemezhetők, vagy egy gyümölcs példáján megállapítható akár az is, hogy az milyen érettségi fokkal rendelkezik. A hiperspektrális képalkotás segítségével olyan folyamatok is megfigyelhetővé, előrejelezhetővé váltak, amelyek kisebb spektrum számmal vizsgáló eszközökkel nem, vagy csak kevésbé megbízható pontossággal történhetett. Összességében elmondható, hogy az orvostudományban és a biológiában is népszerű, és nagy potenciállal rendelkező képalkotó módszerről van szó.

A lehetőségek persze más irányokban is körvonalazhatók. A kezdetben űrtechnológiaként szolgáló hiperspektrális képalkotók ma már drónokra szerelve és laboratóriumokban is mindennapos munkaeszközöknek számítanak. Az alkalmazási lehetőségeit tekintve azonban az igazi áttörés a kereskedelembe kapható mobil eszközökbe való beépítésük volna. Számos alkalmazásfejlesztési ötlet, elképzelés van ezzel kapcsolatban is. A hiperspektrális képalkotás és elemzés fejlődésével az említett felhasználási területeken, zöldségek, gyümölcsök, növények vizsgálata akár otthon is megtörténhet a megfelelő elemző szoftverek segítségével. Ugyanígy talajok vizsgálata a kertben, szántóföldeken virtuális szakértők által kiállított szakvéleményekkel, légifelvételek összehasonlításával. Vagy az egészségügyben virtuális orvosok alkalmazása a bőrbetegségek diagnosztikájában, egészségkárosító folyamatok stádiumának megállapításában. Vagyis mindazon területeken, ahol hasznos és jövedelmező az objektumok minél részletesebb megismerése, a hiperspektrális képalkotás és elemzés előtt nagy jövő áll.

A dolgozat első felében (2. fejezet) a hiperspektrális képalkotás lényegi ismertetésére tettem kísérletet, röviden kitérve a képalkotóeszközökre is. Az első rész végén (2.2 fejezet) a képfeldolgozás alapfogalmait majd alapproblémáit soroltam fel, ez utóbbiak a térbeli és spektrális adatok számosságából és a Hughes-jelenség hatásaiból adódnak. A dolgozat második felében (3. fejezet) igyekeztem összegyűjteni néhány olyan mesterséges intelligencia területén alkalmazott módszert (ANN, CNN, SVM, Fuzzy c-közép klaszterezés), melyek a hiperspektrális képelemzési technikákban is használatosak. Próbáltam röviden, lényegre törően a módszerek alapjait is bemutatni. Összességében a hiperspektrális képelemzés világával kapcsolatban azt a következtetést lehetne levonni, hogy széleskörűen kutatott, fejlődő és ígéretes lehetőségeket magában foglaló területről van szó.

5 Felhasznált irodalom

- [1] Dr. Kardeván Péter (2011): Hiperspektrális technológia. Távérzékelési technológiák és térinformatika online, a szolgáltatók és felhasználók online folyóirata. RS&GIS 1. <http://www.rsgis.hu/Hiperspektralis-legifelvetel-terkepek.html>, Letöltés időpontja: 2018. 09. 22.
- [2] Kozma-Bognár Veronika (2012): Hiperspektrális felvételek feldolgozásának és mezőgazdasági alkalmazásának vizsgálata. Doktori (phd) értekezés. Pannon Egyetem - Állat- és Agrárkörnyezettudományi Doktori Iskola, Keszthely. konyvtar.uni-pannon.hu/doktori/2012/Kozma-Bognar_Veronika_dissertation.pdf, Letöltés időpontja: 2018. 09. 22.
- [3] Csorba Ádám (2017): Reflektancia spektroszkópia alkalmazása talajtulajdonságok és talajosztályozási egységek meghatározásban. Doktori (ph.D) értekezés. Szent István Egyetem - Környezettudományi Doktori Iskola, Gödöllő. https://szie.hu/file/tt/archivum/Csorba_Adam_ertekezes.pdf, Letöltés időpontja: 2018. 09. 23.
- [4] Kozma-Bognár Veronika: Hiperspektrális képalkotás. Oktatási segédlet. http://www.digkep.hu/konyv/Hiper/Hiper_v1.0.pdf, Letöltés időpontja: 2018.09.22.
- [5] James Robinson and Peter Kinghan (2018): Using Drone Based Hyperspectral Analysis to Characterize the Geochemistry of Soil and Water. Journal of Geological Resource and Engineering. 2018. 6. 143-150 oldal. <http://www.davidpublisher.org/Public/uploads/Contribute/5b85fc7678c9e.pdf>, Letöltés időpontja: 2018. 09. 23.
- [6] Hámori Ádám (2012): Hiperspektrális felvételek feldolgozási technikái. Szakdolgozat. ELTE IK Programozásmélet és Szoftvertechnológiai Tanszék, Budapest. http://people.inf.elte.hu/fekete/tamop_2010/Szakdolgozat_diploma/Hamori_A_diplomamunka.pdf, Letöltés időpontja: 2018.09.27.
- [7] Carlos Gershenson (2003): Artificial Neural Networks for Beginners. https://www.researchgate.net/publication/1956697_Artificial_Neural_Networks_for_Beginners, Letöltés időpontja: 2018.09.28.
- [8] Wei Hu, Yangyu Huang, Li Wei, Fan Zhang and Hengchao Li (2015): Deep Convolutional Neural Networks for Hyperspectral Image Classification. Journal of Sensors. Volume 2015, Article ID 258619, 12. <https://www.hindawi.com/journals/js/2015/258619/>, Letöltés időpontja: 2018.09.28.
- [9] Pang-Ning Tan, Michael Steinbach, Vipin Kumar (2011): Bevezetés az adatbányászatba. Panem kft. 2011. https://www.tankonyvtar.hu/hu/tartalom/tamop425/0046_adatbanyaszat/ch05s05.html, Letöltés időpontja: 2018.09.27.
- [10] Yi Wang, Hexiang Duan (2018): Classification of Hyperspectral Images by SVM Using a Composite Kernel by Employing Spectral, Spatial and Hierarchical Structure Information. Remote Sensing. 10(3):26. 2018. https://www.researchgate.net/publication/323696532_Classification_of_Hyperspectral_Images_by_SVM_Using_a_Composite_Kernel_by_Employing_Spectral_Spatial_and_Hierarchical_Structure_Information, Letöltés időpontja: 2018.09.28.
- [11] Maria C. Alonso, José A. Malpica, Alex Martínez de Agirre (2011): Consequences of the Hughes Phenomenon on some Classification. University of Alcalá, School of Geodesy and Cartography. Madrid https://www.researchgate.net/publication/283485444_Consequences_of_the_Hughes_phenomenon_on_some_classification_Techniques, Letöltés időpontja: 2018.09.28.
- [12] José Valente de Oliveira, Witold Pedrycz (2007): Advances in Fuzzy Clustering and its Applications. John Wiley & Son's, Ltd. 2007. https://books.google.hu/books?hl=en&lr=&id=Pn0e1xm4YBgC&oi=fnd&pg=PR5&dq=what+is+fuzzy+clustering&ots=jFtVZMrbRx&sig=sJHZA5GllDEgOOGzylrCK3BnoqU&redir_esc=y#v=onepage&q=what%20is%20fuzzy%20clustering&f=false, Letöltés időpontja: 2018.09.28.