



Mesterséges Intelligencia

LGBIN0851

**A hiperspektrális kép osztályozási
módszerei térbeli és spektrális
tulajdonságai alapján**

Gráczol Benedek Péter

CX77QX

Győr, 2018/19/1.

Tartalomjegyzék

1 Bevezetés	1
2 Áttekintés	2
3 Módszerek	4
3.1. Térbeli és spektrális osztályozás CNN és ritka reprezentációs módszerrel	4
3.1.1. A térbeli mély-tulajdonságok kinyerése CNN módszerrel	4
3.1.2. Osztályozás ritka reprezentációs eljárással	6
3.2. Térbeli és spektrális osztályozás tartóvektor-gép módszerrel (SVM).....	8
3.2.1 Az osztályozási folyamat fő lépései	8
3.2.2 Hiperspektrális kép particionáló klaszterezése ISODATA módszerrel.....	8
3.2.3 Hiperspektrális kép pixel osztályozása (pixel-wise) SVM módszerrel	9
3.2.4 SVM nem-lineáris osztályozó technikája RBF kernel módszerrel	11
3.2.5 A térbeli és spektrális osztályozás	11
3.3. A KNN módszer szerepe a térbeli és spektrális tulajdonságok osztályozásában	12
3.3.1. KNN alapú nem-lokális képszűrés.....	12
3.3.2. Hiperspektrális kép térbeli és spektrális osztályozása KNN módszerrel.....	13
4 Összegzés és fejlesztési lehetőségek.....	14
4.1. Összegzés	14
4.2. Fejlesztési lehetőségek.....	14
5 Felhasznált irodalom.....	17

1 Bevezetés

A dolgozatban a hiperspektrális kép osztályozó módszereinek újabb változatait fogom bemutatni matematikai részletességgel. A hiperspektrális képek osztályozásnak jelentősége abban különbözik a klasszikus képelemzésektől (szürkeárnyaltos/grey-scaled, RGB), hogy az előbbieket esetében akár több száz spektrális csatornáról beszélhetünk, és ebből következően több információ kinyerésére van lehetőség. A hiperspektrális képek a több spektrális dimenzióknak köszönhetően az objektumok részletesebb megjelenítésére képesek, ugyanakkor feldolgozásuk jóval nagyobb számítási kapacitást, és összetettebb módszerek, segéd algoritmusok alkalmazását igényli. A hiperspektrális képeket kezdetben csillagászati objektumok, bolygók, elsősorban felszíni vizsgálatára használták, majd később jellemző felvételezési technikája lett a földfelszín vizsgálatának is, így az agrárium, a környezetvédelem, a hadiipar is egyre inkább támaszkodik a sokrétűbb információkat szolgáltató hiperspektrális felvételekre. Manapság már gyakrabban használnak hiperspektrális képalkotó eszközöket laboratóriumi körülmények között is, amelyek alkalmasak például az orvostudomány területén a bőrfelszín illetve a növényvédelem területén a levélen detektálható betegségek felismerésére. Kisebb hiperspektrális kamerák ma már elérhetők a kereskedelemben is, amelyek gyakran drónokkal együttműködve végeznek felvételezést. A jövőben várhatóan az okos, hordozható készülékekben is megjelennek a beépített hiperspektrális kamerák.

A dolgozatom célja, hogy bemutassa azokat a hiperspektrális képeket osztályozó módszereket, melyek nem csak a spektrális dimenziók elemzését, hanem ezeknek a térbeli összefüggéseit is figyelembe veszik, vagyis az eredményesség érdekében integrálják a térbeli és a spektrális osztályozási módszereket. Korábbi kísérletekben a hiperspektrális felvételek elemzése csak a spektrális csatornák osztályozását érintette, ún. pixelenként való, vagy pixelalapú (pixel-wise) osztályozási eljárásokkal operálva. Manapság viszont, hogy minél pontosabb eredményt kaphassunk, a térbeli-spektrális osztályozás együttes vagy integrált alkalmazása van elterjedőben.

Dolgozatomban három olyan osztályozási módszer matematikai részleteinek bemutatására vállalkozom, amelyek hatékony megközelítéseknek bizonyultak a térbeli és spektrális osztályozás terén. Mivel mind három esetben összetett módszerekről van szó, egy-egy gépi-tanulási (machine learning) modellt hangsúlyosabban szemléltetek. Ebből következően, elsőként egy olyan eljárás kerül bemutatásra, mely a térbeli tulajdonságok kinyeréséhez a **Konvolúciós neurális hálózatok (CNN: Convolutional neural network)** modelljéből indul ki, a spektrális jellemzők osztályozását pedig a ritka reprezentációs eljárással oldja meg. (3.1. fejezet). A következő osztályozási módszer esetében két fő lépésben valósul meg az osztályozás. A módszer első lépésként térbeli összefüggő régiókat keres, melyet egy szegmentációs módszerrel (ISODATA) valósít meg. A második lépésben a spektrális tulajdonságok osztályozásához a **tartóvektor-gép** modellt (továbbiakban **SVM: Support vector machine**) használja fel. A két lépés után kerülhet sor a térbeli-spektrális osztályozásra. (3.2. fejezet). Végül a harmadik megoldás bemutatása során, a **K-legközelebbi szomszéd (KNN: K-nearest neighbor)** egy olyan eljárási módjáról lesz szó, mely valószínűségi térképek generálása után kezdi meg az osztályozási folyamatot. (3.3. fejezet).

2 Áttekintés

Amellett, hogy a kutatási célra felhasználható hiperspektrális felvételek száma egyelőre még nem elég nagy, azt is meg kell említeni, hogy a rájuk vonatkozó módszerek inkább kísérletek, mintsem jól bevált, általánosan alkalmazott osztályozási technikák. A hiperspektrális képelemzéssel foglalkozó tanulmányok általában a klasszikus távérzékeléses felvételeket veszik alapul az osztályozó módszerek teszteléséhez. A dolgozatomban felhasznált fő források szintén távérzékeléses hiperspektrális felvételekre támaszkodva mutatják be a különböző térbeli-spektrális osztályozó technikákat, elemzik azoknak hatékonyságát.

Az első a dolgozatban bemutatandó módszer két légi szenzor hiperspektrális felvételeire támaszkodik. Az első az AVIRIS (Airborne/Visible Infrared Imaging Spectrometer) légi képalkotó, melyek felvételein 224 spektrális sáv érzékelhető, 10 nm-es spektrális felbontásban. A másik szenzor a ROSIS, amely 115 spektrális csatornát képes felvételezni. A következő fejezetben az SVM módszeren alapuló eljárás szintén a ROSIS szenzort használja, végül a harmadik a K-legközelebbi szomszéd módszere pedig az elsőhöz hasonlóan az AVIRIS felvételét. A feldolgozott módszerek tehát távérzékeléses szenzorokkal felvett hiperspektrális képek térbeli és spektrális osztályozását végzik.

Az AVIRIS felvételén egy észak-nyugat Indiana államban lévő fenyő ültetvény, míg a ROSIS-en a Paviai egyetem kampusza látható, zöld környezettel, épületekkel. A távérzékeléses hiperspektrális felvételezés célja lehet geológiai, mezőgazdasági, várostervezési és minden olyan fejlesztési terület, amely nagyobb távolságból minél több információt kíván kinyerni a felvételezést lefedő területről. Attól függően, hogy a felvételek milyen magasságból, milyen szögből, hány spektrális sávot megjelenítve készülnek, egy-egy pixel akár több objektumot is magában foglalhat, illetve akár egy objektum több pixel kompozíciójaként is megjelenhet. Ebből következően a hiperspektrális képosztályozó módszereknél egyaránt szükség van a térbeli és a spektrális jellemzők feltérképezésre is. Mivel mindkét esetben nagy dimenzió számról van szó, a dimenzió redukáló algoritmusok felhasználása már az eljárás elején alapvető lépés.

A dolgozatban bemutatandó három gépi-tanulási módszeren alapuló (CNN, SVM, KNN) térbeli jellemző és pixel osztályozó megoldás, a sok-dimenziós képeket egy-dimenziós képként vagy képek kötegeként dolgozza fel (PCA: Principal component analysis). Ezek az alapkomponeensek (Principal components) aztán további szűréseken is átesnek, míg végül az alapvető tulajdonságok osztályozhatóvá, az objektumok rekonstruálhatóvá válnak. A hiperspektrális képeket a régebbi módszertanok csak spektrális jellemzőik alapján vizsgálták, ám az újabb megközelítések szerint a pontosabb eredmények elérése érdekében, a térbeli tulajdonságok elemzése is szükséges. A dolgozatban bemutatott három tudományos kísérlet, a hiperspektrális kép spektrális és térbeli osztályozásának egy-egy lehetséges módszerét mutatja be az alábbi fő források alapján.

A harmadik fejezetben (3 Módszerek) részletezett első módszer címe ***Hyperspectral Imagery Classification Using Sparse Representations of Convolutional Neural Network Features (Heming Liang and Qi Li)***. Ebben a munkában az osztályozás eredménye az AVIRIS szenzor alkalmazásával, más objektumok mellett, pl. lucernás, legelő, erdők, szója ültetvények, tisztások, épületek azonosítása történik, illetve a Paviai egyetem kampuszának feltérképezése után aszfalt, kavics, fák, fémlemezek és árnyékok is felismerhetők. A felvételek az AVIRIS esetében, 145×145 pixeles tartományban, 20 m per pixel térbeli felbontás mellett készültek (a pixel méret 20×20 méteres területet reprezentál), ehhez képest a ROSIS az épületek és környezeti tárgyak pontosabb feltérképezése érdekében egy 610×340 pixeles képen, 1,3 pixel felbontással végezte az elemzést. A második munka, a ***Spectral-Spatial Classification of Hyperspectral Imagery Based on Partitional Clustering Techniques (Yulija Tarabalka et al.)***, célja az első kísérletben is használt ROSIS szenzor

A hiperspektrális kép osztályozási módszerei térbeli és spektrális tulajdonságai alapján

segítségével szintén csak a Paviai egyetem kampuszán felismerhető objektumok osztályozása volt. Az SVM módszer és az RBF kernel függvény részletes leírásához, a fő forrás hivatkozásait követve a *Support Vector Machines for Hyperspectral Remote Sensing* (J. Anthony Gualtieri, R.F.Cromp) és a *Kernel-Based Methods for Hyperspectral Image Classification* (Gustavo Camps-Valls, Lorenzo Bruzzone) című munkákat is felhasználtam. A harmadik esetében, a *Spectral-Spatial Hyperspectral Image Classification Based on KNN* (Kunshan Huang et al.) című tanulmányban pedig hasonlóan az első forráshoz az AVIRIS képeinek feldolgozása történik, a fentebb felsorolt objektumok osztályozásával, azonos felvételezési paraméterek mellett.

3 Módszerek

3.1. Térbeli és spektrális osztályozás CNN és ritka reprezentációs módszerrel

3.1.1. A térbeli mély-tulajdonságok kinyerése CNN módszerrel

A következő osztályozó módszer a CNN modellt veszi alapul, és két fő lépésből áll. Az algoritmus első lépésként, tekintettel a hiperspektrális kép nagy dimenzió számára a **térbeli mély-tulajdonságok** (spatial deep-features) **kinyerésére** vállalkozik (1.ábra). Amint ezek a térbeli információk rendelkezésre állnak, a **ritka reprezentációs eljárás** (Sparse representation) ezeket felhasználva tovább redukálja a magas szintű térbeli tulajdonságok dimenzióit azzal, hogy az információkat kisebb alterekre vetíti. (2.ábra) Végül az osztályozást az eredményként kapott tanított pixelek szótárának (sparse dictionary) segítségével valósítja meg. (3.ábra)

A módszer célja mintegy 100-200 spektrális sávot reprezentáló képek osztályozása. A módszer a sávokat, dimenziókat PCA-val kötegekbe (PC bands) sorolja, majd az előterjesztéses (feedforward) eljárással egyesével bocsátja feldolgozásra, melynek eredményeként a kimenet egy-egy térbeli mély-tulajdonságokat reprezentáló térkép lesz. (1. ábra)

A konvolúciós folyamatban a kiinduló elemzési terület a receptív mező (receptive field), mely a spektrális dimenziók darabolása miatt két-dimenziós: $P \times P$ (a feldolgozott tanulmányban ez: 28×28) méretű terület. Az adott receptív mezőből kinyert tanuló minták az ábrán X_i -vel vannak jelölve, míg ugyanezen minták címkéi t_i -vel. Ezek a tanuló minták, mint az előző rétegek kimenetei, adják az aktivációs függvény bemeneti értékeit, melyekből generálhatók az aktivációs térképek.[1]

Az aktivációs függvény az egyes rétegekben lép működésbe. A feldolgozott forrásban kétféle réteg szerepel, ezek a konvolúciós és az almintázó (sub-sampling layer) rétegek. A receptív mezők által felvett minták négy rétegen keresztül dolgozzák fel az információkat, így esetünkben két konvolúciós és két almintázó rétegről van szó. Az aktivációs függvény $f(k,b|X)$, ahol k és b a kernelt illetve a bias-t (torzítás, eltolás) jelölik. A biasok mindig csak az adott rétegre érvényesek, a többi rétegtől függetlenek. A kernel, aminek a receptív mező szűrésében van szerepe, ebben az esetben 5×5 -ös pixeltartományt takar be, ugyanis ennél nagyobb kerneleknél, mint például a 7×7 -es vagy a 9×9 -es, nagyobb számítási költségekkel kell kalkulálni. A tanulmányban az aktivációs térképek generálásakor a különböző rétegek, nem lineáris aktivációs függvényeket alkalmaznak.[1]

$$f(x) = (1 + e^{-x}) \quad (1)$$

Az aktuális konvolúciós réteg, kapcsolódva az öt megelőző réteghez, ennek kimeneti térképeinek információiból állítja elő a saját aktivációs térképeit. Ezért az l -edik konvolúciós réteg esetében: $l \in (1, 2, \dots, L)$, [1]

$$F^l = f(F^{l-1} \cdot k^l + b^l) \quad (2)$$

,ahol F^l az aktuális valamint F^{l-1} az előző réteg aktivációs térképét jelölik, k és b pedig a konvolúciós réteg tanítható paramétereiként szerepelnek. A CNN modellben a konvolúciós

A hiperspektrális kép osztályozási módszerei térbeli és spektrális tulajdonságai alapján

rétegek közé gyakran ún. összevonó (pooling) rétegek kerülnek, melyek funkciója elsősorban a feladat komplexitásával járó számítási költség csökkentése. Mindezt az összevonó rétegek azáltal érik el, hogy redukálják a feldolgozandó információk mennyiségét az egyes aktivációs térképeken. Ebben a konkrét esetben az almintázó rétegek (sub-sampling layer) látják el ezt a feladatot, egy ún. *down()* függvényt alkalmazva. A q -adik almintázó réteg esetében ez, $q \in (1, 2, \dots, L)$, [1]

$$F^q = f(\text{down}(F^{q-1}) + b^q) \quad (3)$$

,ahol *down()* az almintázó függvény, amely azzal csökkenti az aktivációs térkép méreteit, hogy átlagértékeket (average pooling) számítva integrálja a kapott eredmény alapján összefüggő területeket. Vagyis a tulajdonságokat reprezentáló számokból képzett átlagértékeket továbbítja a következő rétegnek, mely ezzel kisebb számítási költséggel folytathatja a feldolgozást. A b pedig az almintázó réteg bias tényezőjét jelöli. Ezután már leírható a végső kimeneti függvény is: [1]

$$y(k, b) = f^L(k^L h^{L-1} + b^L) \quad (4)$$

,ahol az $y(k, b)$ CNN folyamat előrejelzett értéke, h^{L-1} pedig az $L - 1$ -edik réteg kimeneti térképe, ami vagy konvolúciós vagy pedig almintázó réteg. Ezután az előrejelzett értéket kell összevetni a célértékkel. A tanuló folyamat során a négyzetes hiba függvény becsüli meg az előrejelzett és a célérték közti szórást. Ez N darab tanuló minta esetén: [1]

$$\min E^N = \frac{1}{2} \sum_{i=1}^N \|t_i - y_i(k, b)\|_2^2 \quad (5)$$

Az előrejelzett- és a célérték közelítésre a visszaterjesztéses algoritmus (backpropagation) jöhet szóba megoldásként. A visszaterjesztéses algoritmus lefutásával határozhatjuk meg a számítást befolyásoló k és b értékeit. Majd visszatérve a folyamat kezdeti lépéséhez, hogy az előterjesztéses algoritmus újabb hibabecsléseket adhasson, a folyamat újra paraméterezése szükséges. Ez a előterjesztéses-visszaterjesztéses eljárás egészen addig folytatódik, amíg a konvergencia kritériumnak megfelel. Ezzel kapjuk meg k és b optimális értékeit. A térbeli mély-tulajdonságokat tehát, melyeknek kinyerése a módszer első részének célja volt, ezekkel a tanított k és b paraméterekkel definiálhatjuk. [1]

$$O = f^L(kX_i + b) \quad (6)$$

,ahol O a végső kimeneti térkép. Végül az is fontos, hogy a kimeneti térképet a pixelosztályozás érdekében egydimenziós vektorra lapítsuk (flattening), egy a tanulmányban leírt transzformáló függvény segítségével. Ezek után elmondható, hogy a kinyert mély-tulajdonság térképek, egydimenziósra lapított vektorokként használhatók fel a ritka reprezentációs eljárásban: [1]

$$D_i = \text{vectorize}(O) \quad (7)$$

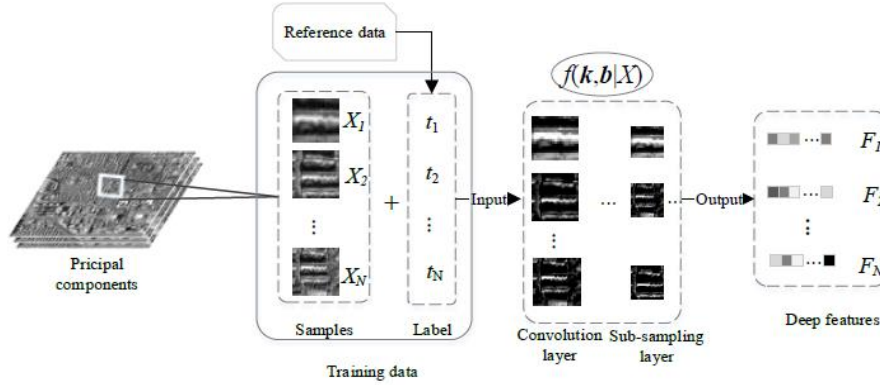


Figure 2. The process of CNN-based spatial feature extraction. The training samples are squared patches. The convolution layer and sub-sampling layer are interspersed in the framework of CNN.

1.ábra: Térbeli mély-tulajdonságok kinyerése CNN módszerrel [1]

3.1.2. Osztályozás ritka reprezentációs eljárással

Az előző fejeztben a dimenzió csökkentett hiperspektrális képek térbeli mély-tulajdonságainak kinyeréséről esett szó. A pixelek osztályozása érdekében azonban a magas szintű térbeli tulajdonságok további dimenzió redukciójára is szükség van. Itt kerül szóba a ritka reprezentációs eljárás, ami a mély-tulajdonságok altereinek (subspace) meghatározásaival vesz részt az osztályozási folyamatban. A ritka reprezentáció esetében a nagy dimenziójú tulajdonságok alacsony dimenziójú alterekre történő vetítéséről van szó, melyeket azonos osztályokhoz tartozó gyakorló pixelek (atoms) képeznek.

Legyen x_i egy nem ismert gyakorló pixel, mely valamennyi osztályból származó gyakorló pixelek egy lineáris kombinációjaként írható le, $x_i \in R^{M \times n_c}$, ahol M a mély-tulajdonságok dimenziója D -ben (lásd 7. képlet). A gyakorló pixelek összességét egy A jelű strukturális szótár (dictionary) tartalmazza, mely osztályok sorozatát alkotja. $A = [A_1, \dots, A_c, \dots, A_C]$, ahol C az osztályok száma és $\sum_{c=1}^C N_c = N$, az elemi egységek (atom) vagy gyakorló pixelek száma A -ban. Az x_i tehát A szótár gyakorló pixeleinek egy lineáris kombinációja: $x_i = A\alpha$, ahol $\alpha \in R^n$ ritka együtthatója az x_i pixelnek, melyet az alábbi optimalizációs probléma megoldásával kaphatunk meg.[1]

$$\hat{\alpha} = \arg \min \|\alpha\|_0, \text{függően a } \|x_i - A\alpha\|_2 \leq \delta - \text{tól} \quad (8)$$

,ahol $\|\alpha\|_0$ α ℓ_0 -normája, mely az együttható vektor nem nulla tagjainak számát reprezentálja, δ pedig a hibatűrés, mely zajokra és lehetséges modellezési hibákra utal. Azonban az említett optimalizációs probléma nehézségét annak nem-determinisztikus mivolta okozza. Vannak ugyanakkor algoritmusok, amelyek ezt a problémát hatékonyan oldják meg.

A hiperspektrális kép osztályozási módszerei térbeli és spektrális tulajdonságai alapján

Ilyen például a bázis követő (BP: Base pursuit) illetve az ortogonális illesztés követő (OMP: Orthogonal matching pursuit) algoritmus. A bázis követő algoritmus az ℓ_0 -normát ℓ_1 -normára cseréli, amivel az optimalizációs probléma a következőképpen módosul:[1]

$$\hat{\alpha} = \arg \min \|\alpha\|_1, \text{függően a } \|\alpha\|_0 \leq K - \text{tól} \quad (9)$$

,ahol K a szótárból kiválasztott atomok, vagyis gyakorló pixelek számára utal. Az OMP algoritmus minden iterációja az A szótár és az R különbség vektor, $R = x - A\alpha$ korrelációján alapul. Minden iterációval az OMP megkeresi annak az atomnak az indexét, amelyik legközelebb esik az R különbséghez, és hozzáadja az atom-mátrixhoz, majd új atomokkal frissíti a különbség mátrixot és kiszámítja α -át. Ha a hibabecslés értéke egy bizonyos, előzetesen meghatározott érték alá esik, akkor az OMP megtalálta a ritka együttható vektort, $\hat{\alpha}$ -t. Az x_i osztálycímkéje, x_i -vel és x_i valamennyi osztály alkönyvtáraihoz való közelségének minimális reprezentációs hibájával határozható meg.[1]

$$\hat{c} = \arg \min_c \|x_i - A_c \hat{\alpha}_c\|_2, c = 1 \dots, C \quad (10)$$




Figure 3. The process of deep feature-based sparse representation classification.

2. ábra: A ritka reprezentációs eljárás osztályozó folyamata[1]

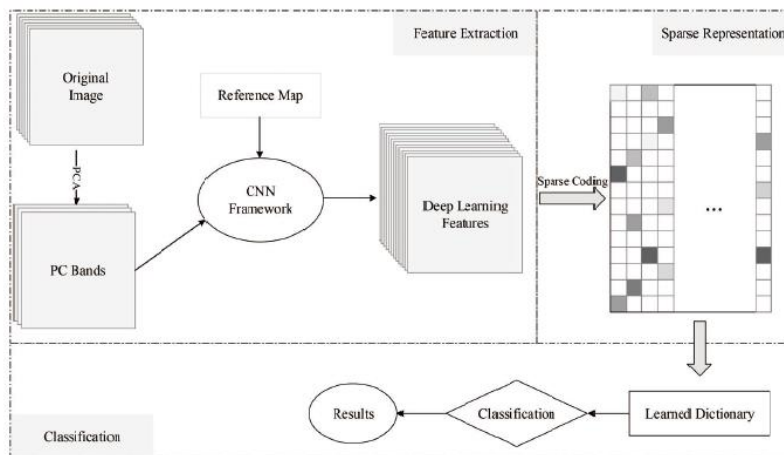


Figure 1. Graphical illustration of the convolutional neural networks (CNN)-based spatial feature extraction, sparse representation and classification of hyperspectral images.

3. ábra: Az osztályozó módszer ábrája, a CNN alapú és ritka reprezentációs eljárással[1]

3.2. Térbeli és spektrális osztályozás tartóvektor-gép módszerrel (SVM)

3.2.1 Az osztályozási folyamat fő lépései

A következő osztályozó folyamat a tartóvektor-gép módszert (SVM: Support Vector Machine) alkalmazza a pixel tulajdonságok kinyerésére. A térbeli és spektrális tulajdonságok osztályozásához, azonban szükség van a tulajdonságok térbeli szegmentációjára is, amihez a partíciós klaszterezés nyújt megoldást. Az alábbi felsorolás az osztályozó folyamat fő lépéseit szemlélteti:

1. Inputok X (n db pixel)
2. **Klaszterezés**
 - a. PCA
 - b. Hasonlóság mérés \rightarrow távolság függvények
 - c. Csoportosítás \rightarrow particionálás \rightarrow ISODATA
3. CCL \rightarrow **szegmentációs térkép**
4. SVM \rightarrow **pixel osztályozás**
5. 3. + 4. \rightarrow **térbeli és spektrális osztályozás**

3.2.2 Hiperspektrális kép particionáló klaszterezése ISODATA módszerrel

A klaszterezés lényegében pixelek csoportosítása a spektrális térben. A klaszterezés folyamatában a **képek, pixelek csoportjaiként képezik a bemeneti adatokat**, az inputot. $X = \{x_j \in R^B, j = 1, 2 \dots n\}$, ahol B a spektrális sávok számát jelöli, n pedig az inputok számát.[2]

A klaszterezés három fő lépésből áll, melyek a **tulajdonságok szelekciója**, kinyeréséből, a hasonlóság mérésből, és a csoportosításból állnak. A tulajdonságok kinyeréséhez a spektrális dimenziók csökkentése az első lépés, ezt a PCA (Principal component analysis) algoritmus végzi. A hasonlóságok, spektrális hasonlóságok, melyek közös klaszterekbe kerülnek az eljárás során. A **hasonlóságok mérése** távolság függvényekkel történik spektrális párokra alkalmazva. A **pixelek csoportosítása**, tulajdonképpen azon optimális partíciók kialakítását jelenti, melyek a klaszterezés folyamatában részt vesznek. $Q_c^i = \{x_{j,c}^i \in R^B, j = 1, 2 \dots m_c^i\}$, ahol Q a partíciót jelöli, m_c^i pedig a pixelek számát az i -edik partícióban. A klaszterezés tehát egy iteratív eljárás, és megvalósítására olyan módszerek alkalmazhatók, mint az ISODATA vagy az EM (Expectation maximization) algoritmus. **Az ISODATA a négyzetes hiba függvényt használja** a klaszterezés során. A négyzetes hiba függvény egy X kép Υ klaszterezése esetében, a következő:[2]

$$e^2(X, \Upsilon) = \sum_{c=1}^C \sum_{j=1}^{m_c} \|x_{j,c} - \mu_c\|^2 \quad (11)$$

,ahol μ_c a c klaszter középpontja (centroid). Az ISODATA egy determinisztikus klaszterező módszer, ami pixel vektorok véletlenszerű kezdeti partícióját forgatja megjelölt klaszterekbe, majd a továbbiakban aszerint klaszterezi, hogy a hiba távolságot csökkenti iteratív eljárással. Az iterációt addig végzi amíg a konvergencia feltétel teljesül. Az algoritmus megtiltja a klaszterek darabolását, zsugorítását és törlését annak érdekében, hogy minél pontosabb eredményeket produkáljon, és hogy csökkentse az eredmények függőségét az inicializálás során.[2]


A klaszterezés eredményeként az egyes klaszterekhez tartozó pixelek egyedi címkével rendelkeznek. A particionáló klaszterezés eljárások ugyan nem használnak fel térbeli

információkat, de ezek a címkék alkalmasak lehetnek a pixelek képsíkra vetítésére is. Vagyis összefüggő térbeli régiók alakíthatók ki a képsíkon, melyeket a címkék számértékei azonosítanak. A címkézett tulajdonságok térbeli régiókba való elkülönítése a CCL (Connected-Component-Labeling) algoritmussal végezhető el, aminek eredményeként a képtéren négy összefüggő régiót kapunk.[2]

A hiperspektrális kép térbeli és spektrális osztályozásához egyrészt szükség van a partíció klaszterezéssel megkapott kép térbeli régiókra szegmentálására, másrészt a kép pixel alapú elemzésére (pixel-wise), melyek a pixeleket egymással összevetve vizsgálják, majd tulajdonságaik alapján osztályozzák.[2]

3.2.3 Hiperspektrális kép pixel osztályozása (pixel-wise) SVM módszerrel

A pixelek osztályozására az előzőekben ismertetett térbeli szegmentálástól függetlenül kerül sor. A tanulmányban szereplő módszer a lineárisan elkülöníthető gyakorló pixelek esetében az SVM-re, míg a nem-lineáris mintáknál az RBF algoritmusra hivatkozik.



4. ábra: Hipersík optimális elhelyezkedése, +1 osztály (kőralakú); -1 osztály (rombusz)[3]

Az SVM címkézett adatpárokkal dolgozik. Legyen l a gyakorló adatpárok száma, így $(y_i, x_i, i = 1 \dots l)$, ahol y_i az osztálycímkéket, x_i az n -dimenziós tulajdonság vektorokat jelöli. Az SVM egy hipersíkkal választja el egymástól a különböző adatokat. Ezért kétféle adatról beszélhetünk. A hipersík tehát ebben az értelemben két osztályt választ el egymástól. Az egyik a +1, míg a másik a -1 osztályra utal, melyek a hipersíktól két oldalán helyezkednek el. A hipersík egyenlete a következőképpen írható le.[3]

$$w \cdot x + b = 0 \quad (12)$$

ahol x a hipersík egy tetszőleges pontja, w egy n -dimenziós vektor, ami merőleges a hipersíkra, b pedig az origóhoz legközelebbi pont távolsága. Az osztályozó függvény egy szignum függvény.[3]

$$f(x; w; b) = \text{sgn}(w \cdot x + b) \quad (13)$$

A hiperspektrális kép osztályozási módszerei térbeli és spektrális tulajdonságai alapján

A hipersík irányát a w vektor iránya határozza meg. Legyen d_i a hipersíktól való távolság, bármely x_i vektorra.[3]

$$d_i = y_i \frac{w}{|w|} \cdot (x_i - x) \quad (14)$$

Az y_i biztosítja, hogy a d_i pozitív lesz. A hipersík függvényét felhasználva x -szel egyszerűsíthetünk.[3]

$$d_i = y_i \frac{(w \cdot x_i + b)}{|w|} \quad (15)$$

A gyakorló minták, pixelek a hipersíktól való távolságtól maximalizálhatók illetve minimalizálhatók.[3]

$$\max_{w, b} \min_{i = 1 \dots l} \left[y_i \frac{(w \cdot x_i + b)}{|w|} \right] \quad (16)$$

A hipersíktól párhuzamos irányban elindulva mindkét mintatípus felé közelítve, az első mintához érve húzzuk egyeneseket, melyek így egy-egy margót alkotnak. A hipersíkot ezek után úgy kell meghúzni, hogy a két margótól egyenlő távolságra legyen. A margóra eső mintákat vagy vektorokat nevezzük **tartóvektornak** (support vector), melyek az osztályozás során lényeges információk.[3]

$$y_i(w \cdot x_i + b) - 1 \begin{cases} = 0 & , \text{ha } i \text{ tartóvektor} \\ > 0 & , \text{ha } i \text{ nem tartóvektor} \end{cases}$$

,vagy

$$y_i(w \cdot x_i + b) - 1 \geq 0 \quad i = 1, \dots, l$$

A hipersíkhöz legközelebbi gyakorló minta a $|w|^{-1}$ -vel fejezhető ki.[3]

$$\max_{w, b} |w|^{-1}$$

$$y_i(w \cdot x_i + b) - 1 \geq 0 \quad i = 1, \dots, l$$

(17)

Konvenció a maximalizációt $|w|^{-1}$ felcserélni a minimalizációra $\frac{1}{2}|w|^2$, mivel ekvivalens kifejezésekről van szó. A minimalizációban az $\frac{1}{2}$ konstansnak csak formális jelentősége van. Az optimális hipersík megtalálására tehát:[3]

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2}|w|^2 \\ y_i(w \cdot x_i + b) - 1 & \geq 0 \quad i = 1, \dots, l \end{aligned} \quad (18)$$

3.2.4 SVM nem-lineáris osztályozó technikája RBF kernel módszerrel

Az előzőekben az SVM módszer lineáris osztályozási eljárását mutattuk be, ugyanakkor a lineáris függvények nem minden esetben hatékony megoldások az osztályozási feladatok során. Ezekben az esetekben a **nem-lineáris megoldások** jöhetnek szóba. Az SVM módszerrel kapcsolatban a **kernel függvények** alkalmazása említhető meg, melyek a gyakorló mintákat, vektorokat egy nagy dimenziójú Euklédesszi térbe képezik le: $\Phi: \mathbb{R}^n \rightarrow \mathbb{H}$. A lineáris eljárásnál is használt optimális margókeresés, a kernel módszernél az $x_i \cdot x_j$ paraméterek helyett $\Phi(x_i) \cdot \Phi(x_j)$ összefüggésben valósul meg, x_i és x_j kernel értékeként. Ezután, K kernel függvényt a következő módon írhatjuk le.[3][4]


$$K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j) \quad (19)$$

A kernel módszer megvalósítására is többféle megoldás ismert, így lineáris kernelekről, polinom kernelekről illetve az **RBF (Radial basis function)** kernelről beszélhetünk. A példánkban az RBF kernelt alkalmazzuk a gyakorló minták osztályozására:[5]

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right), \sigma \in \mathbb{R} \quad (20)$$

3.2.5 A térbeli és spektrális osztályozás

A hiperspektrális kép térbeli és spektrális osztályozásához egyrészt szükség van egy térbeli régiókra szegmentált illetve egy pixelek szerint osztályozott térképre. Az előbbi a partíciós klaszterezéssel, míg utóbbi az SVM módszerrel állítható elő. A térbeli és spektrális osztályozás a két térkép kombinációjával érhető el, azon a módon, hogy a címkézett tulajdonságok alapján szegmentált térbeli régiókat rávetítjük a pixel tulajdonságok térképére, majd szavazó módszerrel (majority vote) a régiókat, azon tulajdonságok szerint jellemezzük, melyek többséget alkotnak az adott szegmensben.[2]



5. ábra: Összefüggő térbeli régiók és pixel tulajdonságok szavazó módszerrel való osztályozása (az ábra a feldolgozott tanulmányban szereplő képek alapján készült)[2])

3.3. A KNN módszer szerepe a térbeli és spektrális tulajdonságok osztályozásában

3.3.1. KNN alapú nem-lokális képszűrés

A K-legközelebbi szomszéd módszert (K-nearest neighbor) a hiperspektrális képek feldolgozása során leginkább pixel osztályozás céljából alkalmazzák. A pixelek osztályozásánál nagy figyelmet fordítanak az optimális távolságmérésre illetve a tulajdonság térre. A dolgozatban bemutatandó **KNN** szűrő ezzel szemben ahelyett, hogy közvetlenül osztályozná az egyes pixeleket, az egymáshoz térbeli tulajdonságokban hasonló, nem-lokális pixelek felkutatásával végzi a képszűrést. Ahelyett, hogy a pixel értéktartományban keresné a legközelebbi szomszédokat, **a hasonlóságot mutató nem-lokális tulajdonságokat keresi, melyet a K legközelebbi szomszéd módszerrel végez a tulajdonságtérben** (feature space). **A tulajdonságtér egyszerre tartalmazza a pixel értéket és a térbeli koordinátákat.** Az $F(i)$ tulajdonságteret a következő módon definiálhatjuk:[6]

$$F(i) = (I(i), \lambda \cdot l(i), \lambda \cdot h(i)); \quad (21)$$

,ahol $I(i)$ a pixelérték, $l(i)$ és $h(i)$ pedig rendre a pixel hosszúság és szélesség paraméterei. a KNN keresési folyamatban λ szabályozza a pixelérték és a térbeli koordináta közötti egyensúlyt. A KNN szűrési modell tartalmaz egy vezérlő képet I (*guidance image*), egy bementi képet P , és egy kimeneti képet O . (6.ábra) Az I és a P a folyamatban előzetesen ismert, adott képek. A P egy valószínűségi térkép, melyhez a valószínűségi értékeket az SVM módszerrel kapjuk meg. I az első alapkomponeense (principal component) a hiperspektrális képnek. Adott I és P esetén a **KNN alapú nem-lokális szűrő** a következőképpen határozható meg:[6]

$$O(i) = \frac{\sum P(j)}{K}, j \in \omega_i \quad (22)$$

,ahol ω_i a tulajdonságtérben, $F(i)$ -ben talált i pixelnek a K-legközelebbi szomszédjaira utal. $O(i)$ a szűrés kimenetét jelöli. Ha $\lambda=0$, akkor a pixelek közötti térbeli távolságok nem vesznek részt a szűrési folyamatban, és akkor a KNN szűrés nem képes hatékonyan átvinni I térbeli struktúráit P -re. Azonban a térbeli koordináták és a pixel érték ugyanazon tulajdonságtérben való modellezésével, a vezérlő kép (I) térbeli struktúrái alkalmasak a P input kép élesítésére (refine the boundaries). Lényegében ez teszi képessé a KNN-t a hiperspektrális képek térbeli-spektrális osztályozására.[6]

3.3.2. Hiperspektrális kép térbeli és spektrális osztályozása KNN módszerrel

A térbeli struktúrák meghatározását az előző fejezetben bemutatott KNN szűrő algoritmus segítségével érhetjük el. A valószínűségi optimalizáción alapuló spektrális-térbeli osztályozás ezeket a térbeli struktúrákat veszi alapul. (6.ábra)

A következőkben bemutatandó osztályozó módszer a következő két fő lépésből áll. Az SVM osztályozásból és a KNN szűrésből.

1. SVM osztályozó

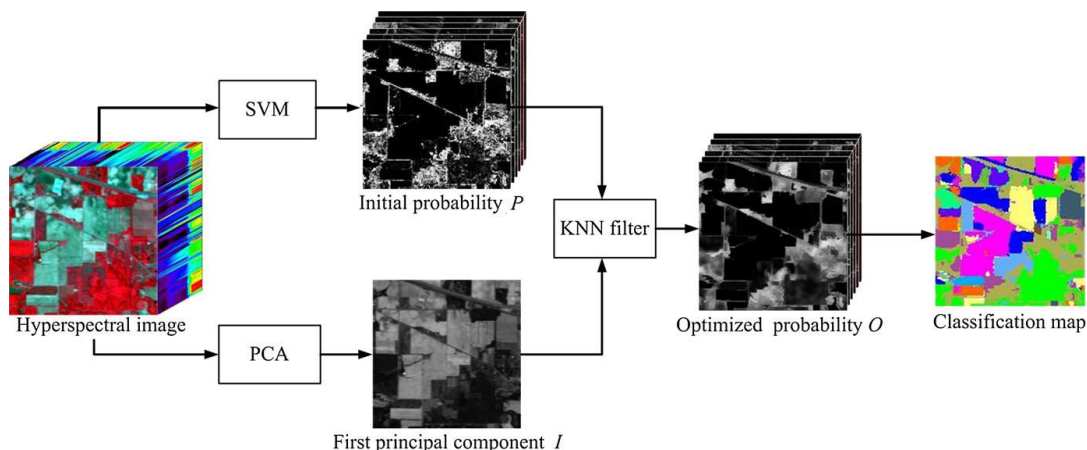
- SVM módszerrel történik a pixelek osztályozása, melynek eredményeként egy valószínűségi térképet kapunk. Ez lesz a P kép, azaz valószínűségi térkép.
- adott egy d -dimenziós hiperspektrális kép, legyen ez

$$x = (x_1, \dots, x_i) \in R^{d \times i}$$
- τ jelölje a gyakorló mintákat

$$T_\tau \equiv \{(x_1, c_1), \dots, (x_\tau, c_\tau)\} \in (R^d \times \mathcal{L}_C), \text{ ahol } \mathcal{L}_C = \{1, \dots, N\} \text{ címkék halmaza és } N \text{ a hiperspektrális kép osztályainak a száma. [6]}$$

2. KNN szűrő

- Alapösszetevő generálás (PCA) célja, egysatornás hiperspektrális kép létrehozása, vagyis esetünkben az I kép generálása.
- Az első alapösszetevő lesz tehát az I kép, a vezérlő kép, mivel a négyzetes átlag értelmében ez adja az optimális hiperspektrális képet, valamint a legfontosabb információkat tartalmazza róla.
- A KNN szűrő ezután feldolgozza a valószínűségi térképet, vagyis a P képet. P_n minden n osztályára vonatkozóan, I vezérlőképpel összevetve.
- Végül az osztályozás aszerint történik, hogy az elemzett pixelek címkéi milyen valószínűségi értékeket vesznek fel. ***A legnagyobb valószínűségi értékek szerint történik tehát az pixelek osztályozása.***[6]



6.ábra: A KNN szűrő szerepe a hiperspektrális kép spektrális-térbeli osztályozásában[6]

4 Összegzés és fejlesztési lehetőségek

4.1. Összegzés

A 3. fejezetben három hiperspektrális képet elemző módszer került bemutatásra. A bemutatott módszerek hiperspektrális képek térbeli és spektrális tulajdonságainak integrált osztályozására vállalkoztak. A spektrális elemzés bonyolultsága a spektrális sávok nagy számából adódik, ezért mind három módszer esetében olyan képek kerültek feldolgozásra, amelyek a PCA (Principal component analysis) eljárással egy-dimenziós képeket, alapösszetevőket (PC: principal components) reprezentáltak. Vagyis a három módszer, hogy csökkentse a számítási költségeket, már eleve kis dimenziójú képeket vont be az osztályozási folyamatba.

Az első (3.1. fejezet), ami a **Konvolúciós neurális hálózatok** mély-tanulás (deep-learning) módszerén alapult, a PC sávokat térbeli dimenziókban csökkentette tovább, majd ezeket alapul véve a spektrális tulajdonságok osztályozását egy-dimenziós vektorokra lapított térbeli tulajdonságokat reprezentáló kimeneti térképek alapján végezte, egy ún. ritka reprezentációs eljárást felhasználva. A második alfejezetben leírt módszer (3.2. fejezet), a térbeli tulajdonságtérképet egy alapvetően spektrális jellemzőket feltáró klaszterezési technikával alakította ki úgy, hogy a spektrális címkéket a térbeli régiók meghatározásához is felhasználta. A spektrális jellemzők elkülönítéséhez az **SVM módszert** alkalmazta, a lineárisan és nem-lineárisan csoportosítható tulajdonságokat is figyelembe véve. Az osztályozás végül egy szavazó szabállyal (majority vote) valósult meg, melynek lényege, hogy az adott tulajdonság szegmensekben vagy régiókban a többséget alkotó azonos tulajdonságú pixelek érvényesüljenek. A harmadik a **K-legközelebbi szomszéd algoritmus** (3.3. fejezet), ami a térbeli elemzést egymással hasonló térbeli tulajdonságú, de nem-lokális pixel szomszédok alapján végezte, feltárva ezzel az egymással összefüggő pixelek térbeli kapcsolatait. A KNN algoritmus spektrális szempontból a pixel vektor tulajdonságait vette alapul, melyekből az SVM módszert felhasználva valószínűségi térképeket generált. A KNN szűrő algoritmus végül a térbeli és spektrális osztályozást a kezdeti valószínűségi térképek élesítésével, finomításával valósította meg.

4.2. Fejlesztési lehetőségek

A dolgozatban bemutatott módszerek tehát légi hiperspektrális felvételeket vettek alapul a térbeli-spektrális osztályozáshoz. A ROSIS légi szenzor mintegy 3000 méter magasságból készít hiperspektrális felvételeket, az AVIRIS viszont jóval nagyobb távolságból, 20 000 méterről teszi ugyanezt. A szóban forgó szenzorokat különböző repülőgépek, - az AVIRIS-t űrrepülőgépek (pl. a NASA ER-2 gépe) - hordozzák. Nyilvánvaló, hogy a felvételezés optimális magassága a szakterületek igényeitől függően eltérő lehet. A dolgozatban bemutatott módszerek pusztán a leírásuk szempontjából voltak lényegesek, és a feldolgozott források fő célja is a módszerek hatékonyságának elemzése volt, ez utóbbi azonban nem képezte munkám részét. Mindazonáltal, ami már a források bevezető részeiből is kiderült, hogy mindegyik módszer alkalmas hiperspektrális képek térbeli-spektrális osztályozására. A hiperspektrális felvételek alkalmazása a múltban kizárólag bolygók felszínének feltérképezésre és a világűr különböző objektumainak a megfigyelésére koncentrált. Azóta a hiperspektrális képalkotás lehetőségeit a földfelszín jelenségeinek vizsgálatával kapcsolatban is felismerték. A dolgozatban tárgyalt módszerek alapjául szolgáló több ezer méter magasságból készült légi szenzoros felvételek, az űrkutatáson túl elsősorban mezőgazdasági vagy városépítészeti célokra használhatók fel. Ugyanakkor újabban már rendelkezésre állnak kisebb hiperspektrális képalkotó eszközök is. Ezek az eszközök is kétféle környezetben kezdenek elterjedni, egyfelől laboratóriumi körülmények között használatosak,

például gyümölcsök vagy növények vizsgálatára, másfelől drónokra telepítve a földfelszín objektumainak azonosítására veszik igénybe egyre gyakrabban.

Az egyik lehetséges fejlesztési irány a mezőgazdasági területek drónos felvételezése hiperspektrális képalkotók segítségével. Ez a terület több szempontból különbözik a magasabb pályákon mozgó légi képalkotókat felhasználóktól. A két megközelítés közös pontja a hiperspektrális érzékelők alkalmazása, ugyanakkor a következő fontos különbségeket említhetjük meg velük kapcsolatban. Például a szenzorok esetében az érzékelhető spektrális csatornák számában, az elérhető felbontásban és a felvételezés magasságában egyaránt különbségekről beszélhetünk. A korábban szóba került légi szenzorok (2 Áttekintés), az AVIRIS és a ROSIS $20 \times 20 \text{ m}$ illetve $1,3 \times 1,3 \text{ m}$ pixel felbontás alapján felvételezhetnek 224 illetve 115 spektrális sávot, a drónos felvételezésénél használt hiperspektrális kamerák 10 - 100 sávot különböztetnek meg, de μm -es pixel tartományban.

A mezőgazdaságban gabonátlálak, ültetvények, konkrét növény fajok jellemzőinek, állapotainak légi felvételezés által való megfigyelésével lehetne felhasználható a hiperspektrális képalkotás. Konkrétan bizonyos növénybetegségek diagnosztikájára, melyek lehetnek hiánybetegségek (tápanyag-, vízhiány stb.) lehetne felhasználni a drón vezérelt hiperspektrális képalkotó technológiát. Ezért a betegségek vagy rendellenességeknek terjedési folyamatába már a kezdeti fázisában be lehetne avatkozni, és a problémától függően szakvéleményeket megfogalmazni.

Ami viszont ezen a területen más technikai megoldásokat követel meg, az nem más, mint az alapvető különbségek ténye a távérzékeléses technológiákhoz képest. A drónos képalkotásnál nemcsak a felvételezés magassága, de a felvételezés célját képező terület is kisebb, mint azon légi szenzoros felvételezési módok esetében, melyekre a dolgozatban bemutatott módszereket alkalmazták. A paraméterek egy másik halmaza a célobjektumok meghatározása vagyis, hogy mely objektumok, ebben a konkrét esetben mely növényfajták illetve a rájuk jellemző betegségek osztályozásáról legyen szó. A dolgozatban ismertetett módszerek alapanyagát képező légi szenzoros, több ezer méteres magasságban készült felvételek olyan osztályozási célból lettek kiválasztva, hogy azokon minél több egyedi objektum meghatározható legyen. A módszerek ugyanis alapvetően kísérleti jelleggel születtek meg, vagyis ezekkel a módszerekkel tulajdonképpen a térbeli-spektrális osztályozás hatékonyságát tesztelték, minél több egyedi objektumot megcélózva. A növények betegségi állapotára vonatkozó drónos feltérképezés esetében viszont a betegségjegyek spektrális tulajdonságainak meghatározásával kell kezdeni. Ezek a spektrális tulajdonságok egy viszonylag szűk halmazt reprezentálnak, így a spektrális dimenziók szűrése is korlátozottabb, mint a légi szenzoros képek esetében. A fényhatások, légi szennyeződések szintén kisebb arányban torzítják a képet, hiszen a felvételezés egyrészt kisebb magasságból történik, másrészt ebben az esetben a felvételezett spektrális csatornák jóval homogénebb környezetben figyelhetők meg. A vizsgálat szempontjából fontos spektrumok így könnyben elkülöníthetők. A rendellenes objektumokat azonosító spektrális görbék arányszáma a képen szereplő többi objektumokhoz képest feltehetően kisebb lesz. A „többi objektum” ugyanis a konkrét, vizsgálat alá vett növény valamely része lesz, ezért indifferens a betegségjegyek osztályozása szempontjából. Másfelől ennek ellentmondva felvetődhet az a probléma is, hogy az egyes felvételeken megfigyelhető hasonló spektrális jellemzőkkel rendelkező szegmensek (homogén régiók), mennyiben fokozzák például a redundanciát. Azzal is számolni kell, mielőtt levonnánk a végső következtetést, hogy vajon a felvételezés magassága (*ami egy drónos megoldás esetén változó*), a feltételezhetően kisebb mértékű fényhatások (*befolyásoló tényező lehet, hogy a felvétel melyik napszakban készül*) vajon mennyire nehezítik az osztályozási folyamatot. A növények adott fenofázisa, hogy éppen melyik fejlődési szakaszban vannak, és olyan a beazonosítást megzavaró jelenségek, mint a levelek szárazsága, deformációja vagy más élőlények, például rovarok jelenléte okán kérdésként

merülhet fel még az is, hogy vajon ezek a tényezők mennyire nehezítik a képképzéssel járó számítógépes adatfeldolgozást.

Feltételezzük ugyanakkor, hogy a számítási kapacitás két szempontból is csökkenthető, egyrészt tehát a kisebb magasságú felvételezési pozícióból, másrészt pedig a vizsgálati terület objektumainak konkrétságából adódóan. Ez utóbbit úgy kell érteni, hogy a vizsgálandó növény, és a növényt reprezentáló spektrumok egy előzetes kalibrációs eljárás után ismertté válnak, és egy ún. spektrumkönyvtárba sorolhatók. Vagyis a képen való objektumkeresés már ismert paraméterminták alapján történik. Természetesen hasonló eljárás érvényes a betegségek vagy rendellenességek spektrumainak meghatározásaira is. Persze ahhoz, hogy elképzeljük ezt a folyamatot a maga teljességében, gondoljunk csak egy konkrét növényfaj egyik jellegzetes betegségére. A növényfaj beazonosítása is egy külön feladat. A tanító mintaként meghatározott ideális paraméterértékekhez kell ugyanis hasonlítani minden egyes felvételezésen felfedezhető objektumot, és addig kell növelni a felvételezéssel a mintaszámot, míg egy elfogadható konvergenciát nem kapunk a célobjektumokra vonatkozóan. Ugyanezt az eljárást a betegségek kapcsán is el kell végezni, de csak akkor, ha már a növény faj az első tanulási szakaszban nagy valószínűséggel meghatározható. A további tanulási ciklusokat pedig az adott területekre vonatkozó információk jelentenék, pl. hogy a betegségek adott körülmények között milyen mértékben terjedtek el, vagy a keletkezett adatok milyen szempontból hasonlíthatók össze korábbi adatokkal. Ezek ismeretében a módszert akár a talajokat érintő folyamatokra is ki lehetne terjeszteni.

Az előzőekben a drónos felvételezési lehetőségek egy lehetséges irányát részletesebben is kifejtettem. A feladat bonyolultságát a növény fajok számossága, a rájuk jellemző betegségek sokfélesége, esetleges mutációik, és amire a dolgozatban bemutatott módszerek is vonatkoztak, maguknak a hiperspektrális képeknek a feldolgozása, térbeli és spektrális osztályozása jelentik. Bár a közeli (kis magasságú) felvételekkel kapcsolatban (*több közeli felvétel alkotja a teljes vizsgálati területet, táblát*) elsőre úgy tűnhet, hogy a növényfajták betegség diagnosztikai célból való drónos vizsgálatához elegendő lenne az egyes felvételek spektrális elemzése is, mégis elképzelhető egy olyan megoldás is, mely ezeknek az amúgy különálló felvételeknek egy összefüggő térképét is elkészíti. Ez a kimeneti/output térkép hasonlóan a hiperspektrális képek térbeli (*3.1.1.fejezet*) vagy spektrális osztálytérképeihez, a konvolúciós neurális hálózati modell segítségével valósulna meg. Egy ilyen megközelítéssel a betegségek terjedési folyamatáról tudhatnánk meg többet, akár azzal, hogy előre jeleznénk azoknak irányát, meghatároznánk azoknak stádiumát vagy más jellegzetes vonásokat figyelhetnénk meg velük kapcsolatban. Kérdés persze, hogy ebből kiindulva megállapítható-e bármilyen tendencia, hiszen már a hipotézis állításhoz is további információk szükségesek, illetve a számítási kapacitás is jelentősen nagyobb lenne, hiszen a neurális hálózat modelleknek nem csak az egyes képek osztályozásakor, hanem ezen osztályképek összesített kiértékelésében is szerepet kellene vállalniuk. Arról nem is beszélve, hogy ez utóbbi esetben maguknak a hiperspektrális felvételeknek is óriási számban kellene rendelkezésre állnia.

Mindenesetre azon felvételekre vonatkozóan, amelyek olyan magasságából és felbontásban készülnek, melyek az egész táblát lefedik, a spektrális és térbeli osztályozási módszerek integrált alkalmazási módjai hasonlóan a légi szenzoros megoldásokhoz eredményesek lehetnek. Az szinte biztosan állítható, hogy egy ilyen szakterületen, mint a mezőgazdaság jelentősen növelni kell az eleve nagy dimenziójú hiperspektrális képek számát ahhoz, hogy a mesterséges intelligencia látványos áttörést tudjon elérni.

5 Felhasznált irodalom

- [1] Heming Liang, Qi Li (2016): Hyperspectral Imagery Classification Using Sparse Representations of Convolutional Neural Network Features. Remote Sensing 8(2), 99. 2016. <https://www.mdpi.com/2072-4292/8/2/99/htm> Letöltés időpontja: 2018.10.26.
- [2] Yulija Tarabalka, Jón Atli Benediktsson, Jocelyn Chanussot (2009): Spectral-Spatial Classification of Hyperspectral Imagery Based on Partitional Clustering Techniques. IEEE Transactions on Geoscience and Remote Sensing, Vol., 47, No. 8. August 2009. http://www.gipsa-lab.fr/~jocelyn.chanussot/publis/ieee_tgars_09_tarabalka_partitional_clustering.pdf Letöltés időpontja: 2018.10.26.
- [3] J. Anthony Gualtieri, R.F.Cromp (1998): Support Vector Machines for Hyperspectral Remote Sensing Classification. Proceedings of the SPIE, Vol., 3584, 221-232 p. 1998. http://www.kernel-machines.org/papers/upload_10967_Svm_u.pdf Letöltés időpontja: 2018.10.26.
- [4] Jakub Busk Sorensen, Kongens Lyngby (2014): Support Vector Machines for Pixel Classification – Application in Microscopy Images. DTU Compute 2014. http://www2.imm.dtu.dk/pubdb/views/edoc_download.php/6790/pdf/imm6790.pdf Letöltés időpontja: 2018.10.26.
- [5] Gustavo Camps-Valls, Lorenzo Bruzzone (2005): Kernel-Based Methods for Hyperspectral Image Classification. IEEE Transactions on Geoscience and Remote Sensing, Vol., 43, No. 6. August 2005. <http://rslab.disi.unitn.it/papers/R36-TGARS-kernel-hyper.pdf> Letöltés időpontja: 2018.10.26.
- [6] Kunshan Huang, Shutao Li, Xudong Kang, Leyuan Fang (2015): Spectral-Spatial Hyperspectral Image Classification Based on KNN. Springer Science + Business Media, New York 2015.