



Mesterséges Intelligencia

LGBIN0851

Gyomnövények osztályozása drónnal készített felvételek alapján

Gráczol Benedek Péter

CX77QX

Győr, 2018/19/1.

Tartalomjegyzék

1 Bevezetés	1
2 Elméleti háttér	2
3 Az osztályozó módszer előkészítése és bemutatása	3
3.1. <i>A felvételezés módja.....</i>	3
3.2. <i>A mintaképek kiválasztásának módja</i>	3
3.3. <i>A pixelek RGB értékeinek kiolvasása</i>	5
3.4. <i>Az átlagszín és euklideszi távolságok</i>	7
3.4.1. <i>Az átlagszín meghatározása</i>	7
3.4.2. <i>Az euklideszi távolságok mérése</i>	8
3.4.3. <i>Kategóriák és kvartilisek</i>	9
3.5. <i>Összevonó módszer és a mintapixel meghatározása</i>	11
3.5.1. <i>Az összevonó módszer célja</i>	11
3.5.2. <i>Az összevonó módszer és eredménye</i>	11
3.6. <i>Az osztályozó módszer</i>	13
3.6.1. <i>Az osztályozáshoz kiválasztott tesztképek</i>	13
3.6.2. <i>Osztályozás távolságkategóriák ($K_{1,2,3}$) alapján</i>	15
3.6.3. <i>Osztályozás K_1, %-ban kifejezett arányai alapján.....</i>	15
3.6.4. <i>A(K) mintapixel K_1 %-os osztályozása.....</i>	17
4 Konklúzió	19
4.1. <i>A módszer értékelése, tanulságok</i>	19
4.2. <i>Fejlesztési lehetőségek</i>	19
5 Felhasznált irodalom.....	20
6 Mellékletek.....	21

1 Bevezetés

A dolgozatom témája egy drónnal készített felvétel elemzése. Az elemzés célja, hogy a képen látható gyomnövények egy saját ötlet alapján kidolgozott módszer segítségével azonosíthatók, osztályozhatók legyenek. Az osztályozó módszer alapja egy meghatározott eljárással kiválasztott mintapixel RGB értéke, amely meghatározott feltételek mellett alkalmasnak bizonyult az objektumok (gyomnövények) azonosítására. A pixelek összehasonlítása azoknak RGB értékei alapján, euklideszi távolságméréssel valósult meg. Az osztályozó módszer is kétféle megközelítés szerint közli az eredményt, az egyik a távolságértékek szerinti, a másik egy sajátos eljárással kiválasztott mintapixel %-os előfordulása szerinti eredményközlés.

A dolgozat érdemi, 3. fejezetének tárgyalása előtt, az osztályozó módszer elméleti hátterét kívánom bemutatni, vagyis lényegében azt a szakterületet, ahol a gyomnövények osztályozásának problémája felmerül. A 3. fejezet elején külön kitérek a felvételezés módjára és körülményeire, amelyek bizonyos mértékben behatárolják az osztályozás eredményeit. Mielőtt azonban rátérnék az osztályozó módszer bemutatására és annak feltételeit megteremtő eljárások részletezésére, a mintaképek kiválasztási módszeréről és a pixel információk kinyerésének módjáról is beszámolok. A pixelek elemzésével ugyanis megkapjuk azoknak szintulajdonságait, a három RGB csatorna értékében kifejezve. A továbbiakban ugyanis ezen RGB értékek alapján lesznek számíthatók a színátlagok, valamint az egyes pixelek és a színátlagok közötti különbségek. A pixelek RGB értékeinek megismerése mind a mintapixel meghatározásának, mind pedig az osztályozó módszer működésének szükséges feltétele.

A dolgozat érdemi része, a 3. fejezet *Az osztályozó módszer előkészítése és bemutatása*, amely tartalmát tekintve két részre bontható. Az első tartalmi rész, ami lényegében a 3.4 és 3.5 fejezetekből áll, a mintapixel meghatározása érdekében tett konkrét megoldások és kísérletek leírását foglalja magában. Az osztályozó módszert tárgyaló 3.6. fejezetben bemutatandó eljárások már az előzőekben meghatározott mintapixel tulajdonságait alapul véve szemléltetik az osztályozás eredményeit.

A dolgozatban az osztályozó módszerhez és a mintapixel meghatározáshoz szükséges adatkinyerést (RGB), számításokat (átlag, euklideszi távolság) Python programnyelven implementáltam. Ezek az átlagszámítót kivéve saját kidolgozású kódok. Ezzel párhuzamosan a kinyert adatokat egy Excel munkafüzetbe másoltam, ahol az adatok összessége átláthatóbb volt, jobban segítve a tendenciák észrevételét, sejtek megfogalmazását. Némely a dolgozatban is megjelenő számítás vagy táblázat, de főként kisméretű képek pixel-modellezése szintén az Excel segítségével valósult meg. A színek megjelenítésére például egy VBA kódot is írtam, amely a cellákba másolt RGB értékek alapján tette láthatóvá a színeket. A programkódokat és a dolgozat tartalmát képező megoldásokkal kapcsolatos táblázatokat, kísérleti elemzéseket és számításokat tartalmazó dokumentumokat a mellékletben tüntettem fel.

2 Elméleti háttér

A drónos felvételek elemzése a különböző szakterületeken belül is sokrétű lehet. A dolgozat témáját szolgáltató drónnal készített felvétel elemzése a mezőgazdasági célú precíziós eljárások támogatásának szándékával készült. A precíziós eljárások célját képező területeknek is több fajtája ismert, hogy csak néhányat említsünk, a víz és tápanyag hiányok felderítése mind a talaj, mind pedig a növények állapotfelmérése alapján, a növénybetegségek és rendellenességek detektálása, előrejelzése illetve a gyomnövények jelenléti arányának felmérése. A dolgozatomban ez utóbbira, azaz a gyomnövények feltérképezésére kívánok megoldást kínálni. Konkrétabban, egy olyan gyomnövényeket osztályozó módszert kívánok bevezetni, amely bizonyos minták alapján képes lesz a megfelelő objektumokat, esetünkben a gyomnövényeket azonosítani.

A gyomnövények osztályozásával kapcsolatban az egyik leggyakrabban előforduló probléma a heterogén elhelyezkedés. A gyomnövények elhelyezkedhetnek kisebb-nagyobb csoportokban, de akár szórványosan is az adott területen belül, a művelés irányának megfelelően vagy attól eltérően.

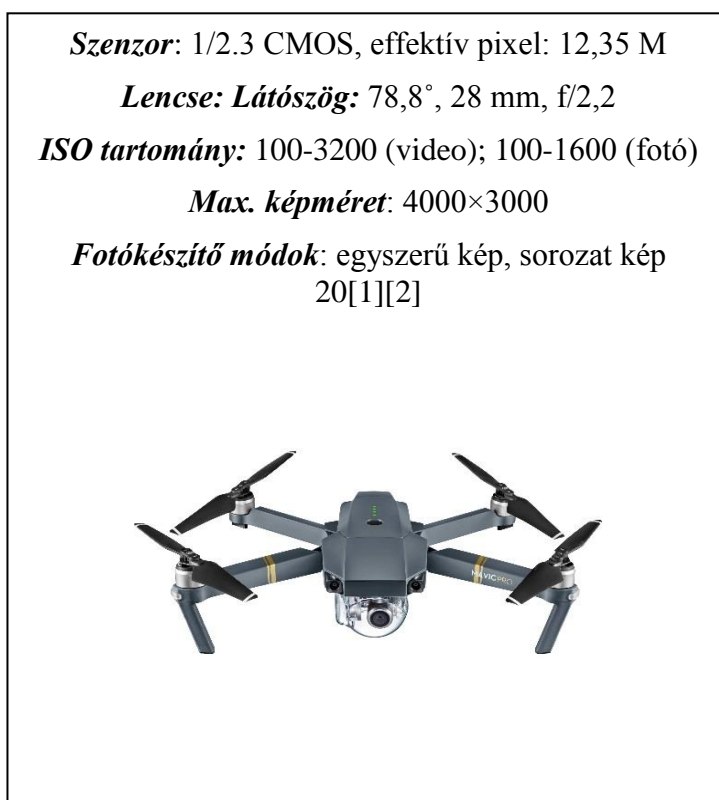
A növények osztályozására fejlesztett módszerek több szempontból is különbözhetnek, például aszerint is, hogy milyen típusú növényeket, növényfajokat céloznak meg. A gyomnövények elterjedésének állapotfelmérése mellett, a kultúrnövények osztályozására is léteznek sajátos módszerek. Ami ezekben a módszerekben közös, hogy mindegyikkel kapcsolatban hasonló természetű problémák fogalmazhatók meg. Itt elsősorban arra kell gondolni, hogy az egyes növényfajok képalkotók segítségével való osztályozási eredményei nagyban függenek a felvételezés, az időjárás illetve a biológiai fejlődésszakaszok, fenofázisok körülményeitől. Ebből következően a mesterséges intelligencia ilyen, alapvetően mezőgazdasági célú alkalmazása talán más területekhez képest is nagyobb erőfeszítéssel jár.

A dolgozatban bemutatandó gyomnövény osztályozására szánt módszer fejlesztési körülményeit illetően, figyelembe kell venni az RGB elemzések korlátait is. A dolgozatban tárgyalandó módszer eredményei ugyanis csak a felvételezés körülményeinek (magasság, képalkotó), időjárási és fényviszonyainak relációjában értékelhetők. Az RGB értékek tehát attól függően változhatnak, hogy milyen napszakban történik a felvételezés (fényviszonyok) vagy hogy milyen az időjárás (ködös, csapadékos, stb...). Ahhoz azonban, hogy még pontosabb eredményt kaphassunk, nem csak az említett körülmények változtatásával, kombinálásával végzett kísérletek segíthetnek, hanem a jelen módszer rögzített körülmények mellett való tovább tesztelése is azzal a céllal, hogy még több mintapixel, még több tesztkép kerüljön feldolgozásra. Ebből következően persze az is sejthető, hogy a fényviszonyok hatásait redukálni vagy más spektrális sávokat (pl. közeli infravörös) érzékelni képes képalkotók megbízhatóbb eredményeket adnak. Jelen feladatban felhasznált drónos felvételek elkészítéséhez ugyanakkor egy RGB kamera állt rendelkezésünkre, így tehát a dolgozat egy drónnal készített kép RGB szerinti elemzésére vállalkozik.

3 Az osztályozó módszer előkészítése és bemutatása

3.1. A felvételezés módja

A felvétel egy DJI Mavic Pro típusú drónnal készült, Tanakajd (Vas megye) külterületén, 10 méteres felvételezési magasságból. A felvétel tulajdonképpen egy ortomozai kép ábrázol, vagyis több kisebb darabból alkotott képről van szó, melynek feldolgozása a pix4D felhőalapú szoftverrel történt. A képen egy őszi búza tarló látható, melyen szórványosan gyomnövények, egész pontosan parlagfű csoportok illetve szórványok fedezhetők fel. A drónra egy RGB kamera van szerelve. A drón képalkotással kapcsolatos paramétereit az alábbiakban foglaltam össze.



1. ábra: DJI Mavic Pro drón és kamerájának paramétereit

Forrás: https://www.bhphotovideo.com/c/product/1323035-REG/dji_cp_pt_000667_mavic_pro_part42_without.htm, Megtekintés napja: 2018.11.22.)

3.2. A mintaképek kiválasztásának módja

A fő kép és a mintaképek kiválasztása nem automatikusan, hanem a kép megtekintő elemzésével, illetve a helyszínen megfigyelhető tényezők, körülmények figyelembevételével történt. A cél alapvetően az volt, hogy a gyomnövényt leginkább kifejező minták legyenek kiválasztva. A 2. ábra, ami tulajdonképpen a fő kép 10 méteres magasságból, drónos képalkotó segítségével készült. A kép jobb oldalán gyomnövények láthatók, ezért a piros négyzet 100×100 pixelt lefedő területe is ennek megfelelően lett kijelölve. A 2. ábrán további négyzetek (két darab) láthatók, szintén piros szegéllyel. Ezek a 10×10 négyzetek reprezentálják majd a mintaképeket, melyek a dolgozatban m₁ illetve m₂ jelöléssel fognak

Gyomnövények osztályozása drónnal készített felvételek alapján

szerepelni. A két mintakép, azaz m_1 és m_2 képezi majd azt az elemzési tartományt, melyet felhasználva a mintapixel RGB értékének megállapítása történik. A két mintakép Excelben 80×80 pixel területen rekonstruált, majd kinyújtott változata pedig a 4. ábrán látható.



2. ábra: A fő kép, melyen a piros négyzet egy láthatóan gyomnövényekkel takart területet fed le. Mérete: 100×100 pixel



3. ábra: A gyomnövényekkel takart területen belül kijelölt 10×10 pixel méretű mintaképek



4. ábra: A mintaképek kinyújtott modellje, balról-jobbra: m_1 és m_2 . Eredeti méretük egyaránt: 10×10 pixel

3.3. A pixelek RGB értékeinek kiolvasása

Annak érdekében, hogy a kiválasztott mintaképek pixeleit, RGB értékeik vagy dimenziók szerint elemezni tudjuk, elsőként ki kell azokat olvasnunk valamilyen formában, valamilyen megoldással. Az RGB értékek kiolvasására jelen feladatban azért van szükség, hogy kiszámíthassuk a mintaképek RGB-ben kifejezett színátlagát. Amint megkaptuk a színeket kifejező paramétereket átlagszámítással eldönthetjük, hogy melyik szín a legalkalmasabb az osztályozási folyamatban való részvételre, azaz melyik RGB érték alapján érhetünk el pontosabb osztályozási eredményeket. A következő kódrészletek a módszer előkészítésének kezdeti szakaszát valósítják meg, azzal a már említett céllal, hogy a mintaképekről (m_1 és m_2 -ről) kiolvassák a pixelek RGB értékeit.

1. kódrészlet: A mintaképek pixel koordinátáit kiolvasó függvény Python nyelven (verzió: 2.7.15)

```
from PIL import Image
import os.path

#fajl neve/minta-kep(m1/m2.png)
img = 'm1.png'
sample = os.path.join('c:\\temp\\',img)

def coord(fajl):
    im = Image.open(fajl) #fajl megnyitasa

    w, h = im.size
    for i in range(w):
        for j in range(h):
            print i,j
    return

print coord(sample)
```

Az **1. kódrészlet** a pixelek koordinátáit olvassa ki abból a célból, hogy később, amennyiben szükséges lokalizálni lehessen az egyes pixeleket. A *coord()* függvény két *for* ciklust tartalmaz, melyek feladata, hogy az adott képen (jelen esetben az *m1.png*-n) pixelről-pixelre végig járjanak és a pixelek szélességi (*i*) illetve hosszúsági (*j*) koordinátaival térjenek vissza. A *w*, a kép szélességének pixelben kifejezett értékét, a *h* pedig hasonlóképpen, a hosszúságát fejezi ki. Mivel a mintaképek esetében négyzetekről van szó, ezért evidens, hogy $w = h$.

2. kódrészlet: A mintaképek pixeleinek RGB értékeit kiolvasó függvény Python nyelven
(verzió: 2.7.15)

```
def get_rgb(fajl):  
    im = Image.open(fajl)  
    w, h = im.size  
    channel = ["R=red", "G=green", "B=blue"] #r,g,b  
    channel_range = [0,1,2]  
    for rgb in channel_range:  
        print channel_range[rgb], channel[rgb], 'csatorna  
ertekei:'  
        for i in range(w):  
            for j in range(h):  
                #pixel felvetel  
                pixel = im.getpixel((i, j))  
                print pixel[rgb]  
    return  
  
print get_rgb(sample)
```

A **2. kódrészlet** a módszer előkészítésének első fontos feladatát valósítja meg azáltal, hogy a mintaképek pixelről-pixelre való bejárása közben, az egyes pixelek RGB paramétereivel tér vissza. A `get_rgb()` függvény hasonlóan az 1. kódrészlet koordinátagyűjtő függvényéhez szintén két ciklussal, a képet szélessége és hosszúsága szerint bejárva gyűjti ki a megfelelő adatokat. Az egyes pixelek RGB értékét az `im.getpixel()` függvény olvassa ki. A `get_rgb()` függvénynek egy argumentuma van, és ebben az esetben a `sample` változó tölti be a szerepét. Ez tulajdonképpen a megnyitandó fájlra utal, esetünkben tehát az `m1.png` vagy `m2.png` mintaképre. A fájl elérési útvonalát tartalmazó `sample` változót az 1. kódrészlet tartalmazza.

A Python kódok segítségével kinyert RGB értékeket egy Excel táblázatban gyűjtöttem össze, és jórészt ott is dolgoztam fel. A fenti kódokat, különös tekintettel a 2. kódrészletre, pusztán az értékek kiolvasására használtam. Az Excel fájlt, akárcsak a kódok teljes példányait a dolgozat mellékleteként fogom megjelölni és csatolni. Ahol a megértés szempontjából szükséges, ott részletesebb ábrákat, kódokat és táblázatokat fogok mellékelni a dolgozat során.

A következő fejezetben (3.4. fejezet) a mintapixelt adó átlagszín meghatározásáról lesz szó.

3.4. Az átlagszín és euklideszi távolságok

3.4.1. Az átlagszín meghatározása

Miután a mintaképek (m_1, m_2) pixeleinek (100 - 100 db) RGB értékek szerinti kiolvasása az előzőekben bemutatott függvényekkel megtörtént, a minta vagy tanító pixelként való bevezetésük érdekében célszerű valamilyen elvből kiindulni. Egy ilyen lehetséges megközelítés *a mintakép* vagy terület *átlagos színének meghatározása*. Ebben az alfejezetben tehát arról lesz szó, hogy miképpen történik az átlagszín meghatározása.

3. kódrészlet: A mintaképek pixeleinek átlag RGB értékeivel visszatérő függvény Python nyelven (verzió: 2.7.15)

```
#fajl neve/minta-kep (m1/m2.png)
img = 'm1.png'
sample = os.path.join('c:\\temp\\',img)

#fajl megnyitasa
im = Image.open(sample)

def average_colour(image):

    colour_tuple = [None, None, None]
    for channel in range(3):

        pixels = image.getdata(band=channel)

        values = []
        for pixel in pixels:
            values.append(pixel)

        colour_tuple[channel] = sum(values) / len(values)

    return tuple(colour_tuple)

print average_colour(im)
```

A 3. *kódrészlet* lényegében azt fejezi ki, hogy az átlagszámító függvény *avarage_colour()* egy *for* ciklussal halad végig a mintakép pixelein (itt: m_1). A pixel színtulajdonságait dimenzióként (R>>G>>B) kiolvassa majd összeadja a megegyező dimenziójú értékeket és a végén kiszámítja az átlagukat: $colour_tuple[channel] = sum(values) / len(values)$, ahol a $sum(values)$ az adott csatorna értékeinek összege, a $len(values)$ pedig a mintaszámok összessége. Az így kapott RGB átlag formátuma: (R, G, B).[3]

A kód lefuttatásával kapott eredmények, *a mintaképek RGB átlagai m_1 -re (164,160,84) illetve m_2 -re (164,156,76)*. A dolgozat további részeiben az átlagszámítás eredménye kerül felhasználásra, valamint az egyes pixeleknél ehhez az átlag értékhez viszonyított távolságai. A távolságmérés az euklideszi távolságmérő függvénnyel történik, ami a következő alfejezetben (3.4.2.) kerül bemutatásra.

3.4.2. Az euklideszi távolságok mérése

Az előző fejezetben kikötöttük, hogy a mintakép pixelek összehasonlítását azoknak átlag RGB értékétől való távolságuk alapján fogjuk végezni, ami konkrétan az euklideszi távolságmérés függvényének segítségével fog megvalósulni. Az alábbiakban a képletet és annak két lehetséges Python nyelvű implementációját fogom bemutatni.

Az euklideszi távolságok mérése tehát a mintaképek (m_1, m_2) pixeleinek átlag RGB értékének és az egyes pixelek RGB értékeinek összehasonlítása alapján történik. Legyen az átlag pixel RGB (p_1, p_2, p_3) , rendre a vörös (R), a zöld (G) és a kék (B) intenzitást kifejező paraméter, míg ugyanezt a vizsgálat alá vetett pixel esetében jelölje (q_1, q_2, q_3) .

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + (p_3 - q_3)^2} \quad (1)$$

4. kódrészlet: Az euklideszi távolság függvény két lehetséges implementációja Python nyelven (verzió: 2.7.15)

```
#euklideszi_0
def euclidean(p1,p2,p3,q1,q2,q3):

    dist=math.sqrt((p1 - q1)**2 + (p2 - q2)**2 + (p3 -
q3)**2)

    return dist

#euklideszi_1
def euclidean(p,q):
    res, channel = 0, 3 #RGB channel = 3

    for i in range(channel):
        res = res + (p[i]-q[i])**2

    return math.sqrt (res)
```

3.4.3. Kategóriák és kvartilisek

A kategóriák kialakítására azért van szükség, hogy egyértelműen látható vagy bizonyítható legyen, hogy vajon a két mintakép pixelei alapján mért átlag RGB értékek (3.4.1. fejezet) megfelelő mintapixeleknek tekinthetők-e vagy pedig további pontosításokat kell végeznünk annak érdekében, hogy az osztályozáshoz szükséges információt megkapjuk.

Miután mindkét mintaképre vonatkozóan ismerjük valamennyi pixel, azoknak RGB átlagától való euklideszi távolságát, megvizsgáljuk a kapott távolságok jellemzőit. Ennek érdekében három távolság tartományt vagy intervallumot vezetünk be. Az átlaghoz legközelebbi pixelek leírására a ≤ 25 tartományt alkalmazzuk, majd a közepes távolságot a $25 < d < 50$ elemek illetve a nagy távolságot reprezentáló értékeket a $50 <$ elemek intervallumába csoportosítjuk. Ezzel tehát három távolság kategóriát hoztunk létre, melyek jelentősége a későbbiekben az osztályozó módszer esetében lesz látható. Az euklideszi távolságmérés segítségével kapott kategóriákat a továbbiakban K_1 , K_2 , K_3 -mal jelöljük, rendre a közelebbitől a nagyobb távolságig.

Kategória jelölés	Távolság intervallum
K_1	≤ 25
K_2	$25 < d < 50$
K_3	$50 <$

1. táblázat: Távolságkategóriák jelölése és az intervallumok

Az 5. ábra pedig az m_1 mintakép egyik kategóriahatárát (K_1 : ≤ 25 illetve K_2 : 25 és 50 közötti távolság kategóriák) szemlélteti. A kék szín a K_1 -hez, míg a piros a K_2 -höz tartozó értékeket jelöli. A *Colour* oszlop az egyes pixelek színeit, míg az $A(m_1)$ az első mintakép átlagszínét szemlélteti.

i,j	i,j	E	R	G	B	Colour	$A(m_1)$
1	0 0	21,93	180	172	93		
98	7 9	23,37	175	179	92		
46	5 4	23,85	152	144	71		
47	6 4	23,85	152	144	71		
62	1 6	23,85	151	148	68		
63	2 6	23,85	151	148	68		
26	5 2	24,19	154	138	85		
27	6 2	24,19	154	138	85		
5	4 0	25,14	152	138	86		
8	7 0	25,57	181	162	103		
6	5 0	26,08	154	136	86		
7	6 0	26,08	154	136	86		
4	3 0	27,17	183	179	88		
40	9 3	28,35	148	138	76		
15	4 1	28,46	153	140	67		
100	9 9	29,77	143	142	73		

5. ábra: m_1 mintakép RGB értékeit és euklideszi távolságait tartalmazó táblázat egy részlete

5. kódrészlet: A három euklideszi távolság kategória kilistázása Python nyelven (verzió: 2.7.15)

```
def dist(b,item):
    for i in range(item):
        print format(b[i], '.2f')
    return

#szamitas

for i in range(w):
    for j in range(h):
        pixel = im.getpixel((i, j))
        if euclidean(average_colour(im),pixel) <= 25:
            b1[item_b1] =
euclidean(average_colour(im),pixel)
            item_b1 = item_b1 + 1
        elif euclidean(average_colour(im),pixel) > 50:
            b3[item_b3] =
euclidean(average_colour(im),pixel)
            item_b3 = item_b3 + 1
        else:
            b2[item_b2] =
euclidean(average_colour(im),pixel)
            item_b2 = item_b2 + 1

print '\nK1: <=25\n'
dist(b1,item_b1)
print '\nK2: 25-50\n'
dist(b2,item_b2)
print '\nK3: 50<\n'
dist(b3,item_b3)
```

Az 5. kódrészlet azt a folyamatot ábrázolja, ahogy a kategóriákhoz tartozó távolságértékeket megkapjuk. A *dist()* tulajdonképpen egy listázó, output függvény, melynek két paramétere a mintaképről kiolvasott RGB értékek és az adott mintakép (m_1 vagy m_2) átlag eredményére vonatkozó euklideszi távolság *euclidean(average_colour(),pixel)*, illetve a darabszám, mely a *dist()* függvényhez tartozó ciklus felső határa (*item_b*). Az eljárás a középső, K_2 ($25 < d < 50$) kategóriát indirekt módon adja vissza, így közvetlenül csak K_1 -re és K_3 -ra vizsgál.

A kategóriák különválasztását a pixelek távolságértékeinek növekvő sorrendbe rendezésével és az Excel feltételes formázás funkciójával értem el. A három különböző színnel jelölt intervallum értékei ezek után már könnyen csoportosíthatók voltak mindkét mintakép esetében (lásd 5.ábra). Ezen a módon tehát megkaptuk a mintaképek 3-3 távolságkategóriáját. A kvartilisek képzésére ezekután azért van szükség, hogy megvizsgáljuk, hogy a kapott átlagértékek mennyiben pontosíthatók vagyis, hogy megválaszoljuk azt a kérdést, hogy a mintaképek pixel átlagaihoz képest van-e optimálisabb pixel, ami hatékonyabb szerepet tölthetne be az osztályozási folyamatban. A kvartilisképzés a kategóriák méretének tovább redukálásával, negyedelésével érhető el, méghozzá azon a módon, hogy a növekvő sorrendbe rendezett távolságkategóriák értékei közül kiválasztjuk

azokat, amelyek a sor első negyedében, kvartilisében helyezkednek el. Mivel a pixel feldolgozás előtt még bizonytalan, hogy melyik kategóriába mely távolságértékek sorolhatók, vagyis nem tudjuk, hogy a kategóriák pontosan hány értéket fognak tartalmazni, ezért nincs garancia a maradéknélküli négyvel oszthatóságra sem. A kvartilisek problémamentes kialakítása tehát csak csekély valószínűséggel történhet meg. Annak érdekében, hogy mindhárom távolságkategóriában elvégezhető legyen a negyedelés, a következő kerekítési szabályt vezettem be. A kvartilis egy m mintakép euklideszi távolság kategóriájára:

$$q_{m_i} = \left\lceil \frac{\left\lfloor \frac{2T}{Q} \right\rfloor}{2} \right\rceil \quad (2)$$

ahol Q egy konstans, ami a kvartilisek számát jelöli ($Q=4$), T pedig az adott kategóriához tartozó euklideszi távolságok számát kifejező paraméter. Vagyis T azt mutatja meg, hogy egy adott mintakép esetében hány darab olyan pixelről van szó, amely 25-nél kisebb egyenlő, 25 és 50 közötti, illetve 50-nél nagyobb euklideszi távolságra van a számított pixel átlagtól. Attól függően tehát, hogy melyik kategóriában vizsgálódunk.

A minta vagy tanító pixel meghatározásához, ugyanakkor csak az első kvartilisekhez ($Q1$) tartozó pixelek fontosak, a többi, vagyis a $Q2$, $Q3$, $Q4$ kvartilis a továbbiakban elhagyható, indifferens. A $Q1$, mint a „legjobb” negyedre reprezentáló halmaz ugyanakkor mindhárom távolságkategóriára alkalmazva lényeges, hiszen ezen kvartilisek összevonásából kapjuk meg azt a lehetséges tanító vagy mintapixel, ami az osztályozó folyamatban részt vehet.

3.5. Összevonó módszer és a mintapixel meghatározása

3.5.1. Az összevonó módszer célja

Az összevonó módszer alapvetően egy kísérlet. Mielőtt ugyanis meghatározzuk az osztályozó módszer kiinduló paraméterének szánt mintapixel RGB dimenzióit, célszerű megvizsgálni, hogy az elemek további szűkítésével **elérhető-e a mintaképek átlagértékeihez** (3.4.1. fejezet) **képest szignifikánsan pontosabb eredmény**. A következő alfejezetben az összevonó módszer lényegét mutatjuk be, majd pedig a kapott eredmények tükrében a további szerepéről is döntünk.

3.5.2. Az összevonó módszer és eredménye

A módszer a mintaképek alapján létrehozott távolságkategóriákkal és ezen kategóriák első negyedéhez tartozó távolságértékeivel folytatódik. A három kategóriát K_1 , K_2 , K_3 -mal jelöltük, míg a Q_1 , ahogy az az előző fejezetben is kiderült, az első távolságnegyedre utal mindhárom kategóriára érve. Az ebben a fejezetben bevezetendő összevonó módszer lényege, hogy ezeket az azonos távolságkategóriába eső Q_1 negyedeket mindegyik mintakép esetében összevonjuk. Az ilyen módon összevont pixelek célja, egy mintapixel meghatározása, egy olyan mintapixelé, amely az osztályozási folyamatban vehet részt. Az összevonás eredményeként kapott pixelszám, mindhárom távolságkategóriára alkalmazva.

$$N = \left\lfloor \sum_{i=1}^n q_{m_i} \right\rfloor \quad (3)$$

Azaz a q_{m_i} (lásd 2. képlet) összegeiből N méretű pixel csoportokat kapunk, melyekből egy újabb átlag számítással megkapjuk a három kategória minta pixeleit. Konkrétan itt arról van szó, hogy az első távolság kategóriát példának választva, az N az m_1 és m_2 minta-kép legjobb negyedében lévő ($Q1$) 25-nél kisebb vagy egyenlő távolságait reprezentáló pixel számának összegét kapjuk meg.

Az összevonás művelete után, szintén egy-egy átlagot számítunk mindhárom kapott minta tartományra vonatkozóan. Az eredmény három RGB érték, mely a kategóriák szerint összeolvasztott negyedek pixeleiből számítható. Ezeket az átlagokat a következő táblázatban láthatjuk:

minta	R	G	B	Szín
$K1-Q1$	163	160	79	
$K2-Q1$	167	156	81	
$K3-Q1$	185	183	104	
$A(K)$	172	166	88	

2. táblázat: A kvartilisekből képzett pixelcsoportok RGB értékei és összevont RGB átlaga ($A(K)$)

Mindenekelőtt azt a következtetést vonhatjuk le a két összevont átlagérték megismerése után, hogy azok között nincs jelentős távolság, vagyis mindkét mintapixel alkalmasnak látszik az osztályozásra, legalábbis azzal a kikötéssel, hogy a K_1 távolságkategória intervallumába eső értékek nem fejeznek ki jelentős, eredménytorzító eltéréseket. A két érték közötti euklideszi távolság két tizedesjegy pontossággal: $euclidean(A(K);A(m)) = 13,34$, ami ezzel a K_1 kategóriához sorolható érték.

Átlag	R	G	B	Szín
$Am1$	165	161	84	
$Am2$	165	156	77	
$A(m)$	165	158	80	

3. táblázat: A mintaképek RGB átlagai és összevont átlaga ($A(m)$)

Vegyük észre, hogy az összevonó módszerrel kialakított kategóriák átlaga, azaz $A(K)$, mindegyik dimenzióban intenzívebb értéket képvisel a mintaképek összevont átlagának RGB értékeihez, azaz $A(m)$ -hez képest. Ebből akár egy olyan következtetést is levonhatnánk, hogy egy ilyen mértékű intenzitás eltolódás már elrugaszkodik a helyszíni bizonyosságon alapuló mintaképek értékeitől. Egy ilyen állítás ugyanakkor további vizsgálatot igényelne, ezért az osztályozó módszer szemléltetésre az $A(m)$ mintapixelt választjuk, de az $A(K)$ mintapixel osztályozási eredményeinek bemutatására is sort kerítünk.

3.6. Az osztályozó módszer


3.6.1. Az osztályozáshoz kiválasztott tesztképek

Az osztályozás folyamatának teszteléséhez három egymástól eltérő mintaképet választottam ki annak alapján, hogy mit ábrázolnak. Az első minta a gyomnövényt, a második a tarlót, míg a harmadik vegyesen ábrázolja mindegyiket. Az előző fejezetekben a mintapixelek kiválasztásánál az volt a fő szempont, hogy az osztályozási folyamatban minél inkább reprezentálja majd a gyomnövényeket. Az osztályozási módszer bemutatására kiválasztott három tesztkép jelölése c_1 , c_2 , c_3 . Az alábbi kép (6. ábra) az eredeti felvétel egy részletét ábrázolja, a piros négyzet pedig azt a tartományt, amelyet a 3.2. fejezetben a tanító, mintapixel meghatározásához választottam ki. A kék négyzet pedig az osztályozási tartomány, ami hasonlóan a piroshoz 100×100 pixel méretű terület.



6. ábra: A mintapixelek meghatározására illetve az osztályozásra kijelölt tartományok

A következő ábra (7. ábra) az előző képből kimetszett kék négyzet tartalmát mutatja, és azt a három 10×10 pixel méretű négyzetet vagy tartományt foglalja magában, amelyek c_1 , c_2 illetve c_3 címkékel az osztályozó módszer fókuszát, vizsgálati területeit alkotják majd. Ahogy az a képről is leolvasható, három különböző cél-objektumot megjelenítő képrészletről van szó.



7. ábra: Az osztályozásra kijelölt 100×100 pixeles tartomány

A három különböző cél-objektumot megjelenítő 10×10 pixeles kép Excelben kialakított pixel modelljeit, illetve az eredeti tesztképek kinyújtott verzióit a következő ábrák szemléltetik:



8. ábra: c₁ minta-kép (tarló) pixel modellje, alatta a 80×80 pixelesre kinyújtott változatával



9. ábra: c₂ minta-kép (kevert) pixel modellje, alatta a 80×80 pixelesre kinyújtott változatával



10. ábra: c₃ minta-kép (gyomnövény) pixel modellje, alatta a 80×80 pixelesre kinyújtott változatával

A fent látható három kép (8,9,10. ábrák) képezi az osztályozás célterületét. A módszertől elvárt eredmény, hogy az előző fejezetek során kiválasztott mintapixelhez viszonyított távolságok alapján meghatározható legyen, hogy az első c_1 képen nem található növény, a másodikon c_2 csak részben tartalmazza azt, míg a c_3 kép bizonyosan a keresett növényt ábrázolja. Ennek alátámasztására *a következő fejezetben két megállapítást, következtetést teszünk.*

3.6.2. Osztályozás távolságkategóriák ($K_{1,2,3}$) alapján

Az osztályozó módszer szemléltetésére mintapixelnek a mintaképek átlagából képzett átlag RGB értéket $A(m) = (165, 158, 80)$ választottuk ki. (3.5.2. fejezet, 3. táblázat).

Elsőként azt kell megvizsgálni, hogy az osztályozó módszer tesztképeire (c_1, c_2, c_3) koncentrálni milyen mértékű pixeltávolságokat figyelhetünk meg. Ehhez a tesztképek RGB értékeinek a kiolvasására is szükség van, amit a dolgozat elején (3.3. fejezet, 2. kódrészlet) ismertetett módon érhetünk el. A számítást a megismert módszerekkel elvégezve azt láthatjuk, hogy a távolságkategóriáknak megfelelően (3.4.3. fejezet) a K_1 , azaz a 25-nél kisebb vagy egyenlő távolságokat kifejező halmaz reprezentálja leginkább a gyomnövényt, míg a más objektumokkal (kevert/vegyes terület, tarló) tarkított képekre vonatkozóan az átlagtól nagyobb távolságokat figyelhetünk meg.

Tesztkép	R	G	B	Szín	Távolság	Kategória
c_1	198	182	162		91,52	K_3
c_2	182	164	111		35,22	K_2
c_3	154	157	75		11,93	K_1

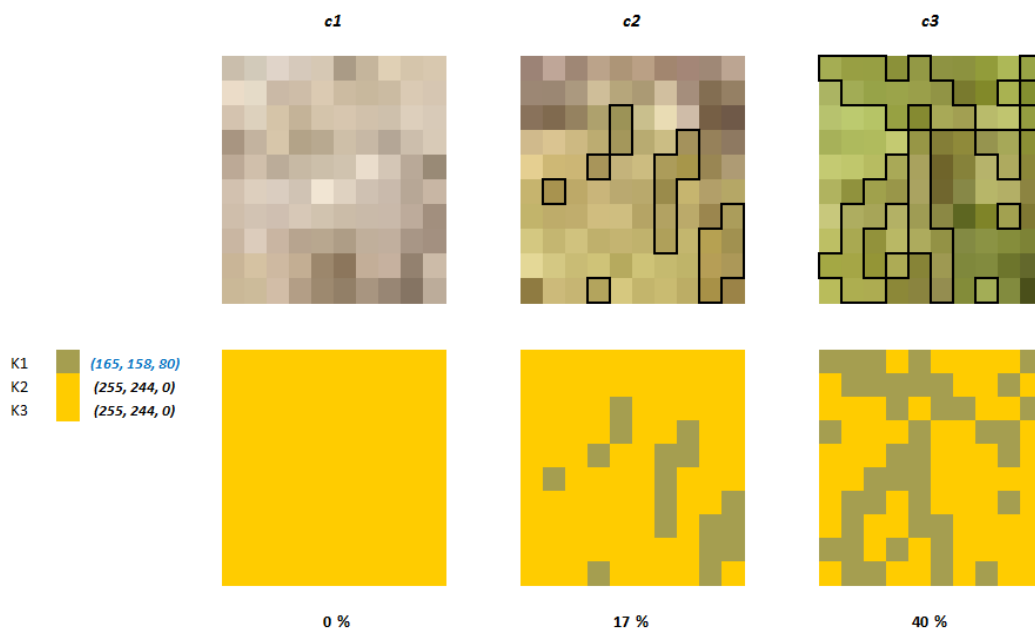
4. táblázat: A c-jelű tesztképek RGB átlagai és a minta RGB-től való euklideszi távolságaik

Az osztályozásra vonatkozó első következtetés a fentiek alapján az, hogy egy c kép RGB átlagára vonatkozó távolságkategória alapján meghatározható az adott kép tartalma. *Azaz K_1 = nem gyomnövényes terület (tarló), K_2 = kevert terület (gyomnövény és tarló), K_3 = gyomnövénnel tarkított terület*

A következő fejezetben pedig az átlagelvnek egy másik megközelítéséről lesz szó, konkrétan annak kimutatásáról, hogy a mintapixelhez legközelebbi (K_1), vagyis a gyomnövényt leginkább reprezentáló pixelek, milyen %-ban vannak jelen az egyes c-jelű tesztképeken, és hogy ez miképpen fejezi ki az adott tesztkép tartalmát.

3.6.3. Osztályozás K_1 , %-ban kifejezett arányai alapján

Mivel a 10×10 pixeles képek esetében 100 pixelről van szó, az egyes kategóriák százalékos arányának kiolvasása nem okoz problémát. A következőkben tehát a c_1, c_2, c_3 tesztképek elemzését végezzük el abból a szempontból, hogy a tesztképek milyen %-os arányban képviselik a gyomnövényt reprezentáló K_1 kategóriához tartozó pixeleket. Az arányok az előző vizsgálatokra alapozva várhatóan markánsan fogják kifejezni a három tesztképen látható tartalmat. Ugyanakkor az már most leszögezhető, hogy pontosabb vizsgálatok érdekében még több tesztkép feldolgozása is szükséges lehet, és a felvételezés körülményei, technikai paraméterei is befolyásolhatják az eredményeket, tehát ezekre is oda kell majd figyelni a további kutatások során. Az alábbi ábrák (11. ábra) elsődleges célja, a dolgozatban bevezetett osztályozó módszer szemléletes bemutatása.



11. ábra: A K₁ távolságkategóriához tartozó pixelek %-os aránya a c jelű tesztképeken

A fent látható képeken (11. ábra) a K₁-es pixelek a mintapixel színével, míg a másik két kategóriához tartozó pixelek (K₂, K₃) a megkülönböztethetőség miatt élénkebb színnel vannak jelölve (255,244,0). A c₁ tesztkép esetében az látható, hogy 0%-ban tartalmazza a mintapixel. A kevert kép (c₂) esetében, amely vegyesen tartalmaz gyomnövényt és tarlót ugyanez az arány már 17%, a gyomnövényt ábrázoló képnél pedig 40%, ami a mintaként választott első képhez (m₁) képest 14%-os százalékos elmaradást mutat. Igaz az m₂-nél ez a különbség csak 9%-os. A szóban forgó %-os eltérések az alábbi táblázat alapján is észrevehetők.

Kép	K ₁ aránya
<i>m1</i>	64 %
<i>m2</i>	49 %
<i>c1</i>	0 %
<i>c2</i>	17 %
<i>c3</i>	40 %

5. táblázat: K₁ pixel előfordulási aránya az m és c képeken

Annak érdekében pedig, hogy az osztályozás eredményeivel kapcsolatban még további pontosításokat érthessünk el, további tesztek elvégzése szükséges, akár más kísérleti körülmények között is. Az elvégzett vizsgálatok tükrében **második következtetésként levonhatjuk**, hogy a %-os arányok közti különbségek is megfelelően szemléltetik a tesztképek által megjelenített objektumokat. Ezért a c₃-as tesztkép, ami a legnagyobb arányban tartalmazza a K₁ azaz a ≤25 minta-pixelhez való távolságú pixeleket, jelen módszer megoldásaival indokolva, alapvetően alkalmas a gyomnövény reprezentációjára.

6. kódrészlet: K_1 kategóriához tartozó pixelek színezése a c-jelű tesztképeken

```
im = Image.open('c:\\temp\\c3.png') #tesztkep valsztasa
pixelMap = im.load()
Ir, Ig, Ib = 165,158,80

def ideal_p(sampleR, sampleG, sampleB):
    r, g, b = 0,1,2
    ideal, non_ideal = 0,0
    pixelsNew = im.load()

    for i in range(im.size[0]):
        for j in range(im.size[1]):
            if euclidean(sampleR, sampleG,
sampleB,pixelMap[i,j][r],pixelMap[i,j][g],pixelMap[i,j]
[b]) <= 25:
                pixelMap[i,j] = (Ir,Ig,Ib,255)
                ideal = ideal + 1
            else:
                pixelMap[i,j] = (255,204,0,255)
                non_ideal = non_ideal + 1

    return ideal, non_ideal, im.show()

print ideal_p(Ir, Ig, Ib)
```


A 6. kódrészlet a 11. és a 12. ábrán látható képeket hozza létre azáltal, hogy a megfelelő, a minta-pixel értékeitől ≤ 25 euklideszi távolságra lévő pixeleket a mintapixel színére ($I_r=165$, $I_g=158$, $I_b=80$), míg a más távolságokat kifejező pixeleket egységesen élénkebb, sárgás színre színezi. A függvény mindkét esetben azt is megszámolja, hogy hány darab pixelről van szó (*ideal*, *non_ideal*), ami alapján megállapíthatók a %-os arányok, így például c_3 (10×10) esetén 40 darab első kategóriás (K_1) pixelről van szó, ezért annak 40%-os előfordulási arányáról beszélhetünk.

3.6.4. $A(K)$ mintapixel K_1 %-os osztályozása

Az m_1 és m_2 mintaképek összevont átlaga $A(m)$ alapján történő osztályozás eredményét az előző fejezetben láthattuk. Most az első kvartiliseket összevonó módszer mintapixelével $A(K)$ -val is elvégezzük az osztályozást.

Arról van itt szó, hogy a gyakoriság elemző módszert kiterjesztjük az $A(K)$ mintapixelre, elsősorban abból a célból, hogy az $A(m)$ mintapixellel összehasonlítva szemléletesebbé tegyük az osztályozás eredményét. Az is látható lesz egyúttal, hogy végül melyik mintapixel ér el jobb eredményt a gyomnövény osztályozásában.

Az osztályozás eredményével kapcsolatban ugyanakkor le kell szögeznünk, hogy a mintapixel „jóságának” egyértelmű meghatározásához, még sokkal több tesztképre és elemzésre lenne szükség. Most azonban arról, hogy melyik mintapixel alkalmasabb az osztályozás eredményét illetően, az egyszerű többség fog dönteni.



12. ábra: Az $A(m)$ és $A(K)$ mintapixelek összehasonlítása c-jelű tesztképeken való előfordulásuk alapján

Kép	$A(m)$	$A(K)$
$c1$	0 %	0 %
$c2$	17 %	23 %
$c3$	40 %	34 %

6. táblázat: Az $A(m)$ és $A(K)$ mintapixelek előfordulási arányait összefoglaló táblázat

Ahogy az a 12. ábrán és a 6. táblázatban is látható az $A(K)$ összevonó módszer segítségével kapott mintapixel nem ad jobb osztályozási eredményt a gyomnövény (c_3) azonosítására vonatkozóan, mint az $A(m)$ mintapixelet. A növényt egyáltalán nem vagy elhanyagolható mértékben tartalmazó c_1 tesztkép esetében mindkét mintapixel egyaránt 0%-os osztályozási eredményt produkált, ugyanakkor a kevert kép esetében az $A(K)$ nagyobb arányban reprezentálta a gyomnövényt. Itt megjegyzendő az is, hogy a kevert képek elemzése tekintetében talán érdemes lenne további vizsgálatokat végezni, hiszen az ilyen típusú képek esetében a térbeli szegmentálás is szükséges lehet a pontos eredmény elérése érdekében.

A fejezet lezárásaképpen megállapíthatjuk, hogy *az osztályozás folyamatát szemléltető $A(m)$ mintapixel a feladat célját, azaz a gyomnövények azonosítását illetően jobb eredményt ért el, mint az összevonó módszerrel kapott $A(K)$ mintapixel.*

4 Konklúzió

4.1. A módszer értékelése, tanulságok

Összefoglalva az osztályozó módszer eredményeit két észrevételt is tehetünk. Az eredmények egyfelől igazolják a 3.2. fejezet mintaképeinek kiválasztását, hiszen mind az euklideszi távolságkategóriák mind pedig az első kategóriához (K_1) tartozó pixelek arányai elfogadható eredményekkel utaltak az objektumra, esetünkben tehát a gyomnövényre. Másfelől viszont a módszer korlátoltságát is észre kell venni. A dolgozatban bemutatott módszer csak olyan kis számú és manuálisan kijelölt területeken végzett osztályozást, amelyek szemmel láthatóan is jelentős mértékben reprezentálták a gyomnövényt. Amíg a c_3 kép osztályozása az ismert feltételek mellett eredményesnek mondható, addig a kevert, c_2 képről már nehezebb egyértelműen megállapítani, hogy az mennyire felel meg az azonosítani kívánt objektumnak. Úgy tűnik, hogy amíg nem áll rendelkezésünkre még több adat, még több mintakép esetleg többfajta pixeltulajdonság, addig a dolgozatban bemutatott osztályozó módszer, mind a távolságkategóriák szerinti, mind pedig K_1 %-os arányai szerinti eredménye csak a három c -jelű tesztkép relációjában értékelhető. Mindezeket megfontolva az osztályozó módszer hatékonyságáról annyit mondhatunk, hogy a feladatban kijelölt célokat adott körülmények között, meghatározott feltételekkel ugyan, de teljesítette. Ezzel együtt a módszer megbízhatóságának további tesztelése érdekében még több mintakép feldolgozása, illetve más felvételezési körülmények kipróbálása is indokoltnak mondható.

Összességében tehát az eredményekkel kapcsolatban az állapítható meg, hogy az osztályozási módszer (3.6. fejezet), és beleértve az azt megelőző mintapixel kiválasztását végző eljárást is (3.4. és 3.5. fejezet), csak a feladatban ismertetett körülmények között és az ezekre alapozott célkitűzések tükrében tekinthető alkalmas módszernek. További fejlesztési irányokra, pontosítási módszerekre a következő 4.2 *Fejlesztési lehetőségek* fejezetben kívánok javaslatot tenni.

4.2. Fejlesztési lehetőségek

A dolgozatban bemutatott gyomnövények osztályozására fejlesztett módszer tehát elsősorban, további mintaképek bevonásával lehetne pontosítható, illetve alkalmasságának mértéke is főleg ez alapján lenne megállapítható. Jelen körülmények között ugyanis egy képről, egy bizonyos magasságról, egy konkrét típusú kameráról beszélünk, amelyek a módszer fejlesztése szempontjából egyaránt változtatható paraméternek tekinthetők. Felvételezhetünk például magasabbról, más fényviszonyok között, kipróbálhatunk más kamerákat, több spektrális sávot érzékelő képalkotókat (multispektrális, hiperspektrális), vagy maradhatunk a klasszikus RGB kameráknál, és vizsgálhatjuk a pixeleket a három csatorna értékein túl, akár HSV (Hue, Saturation, Value) színterek szerint is. A pixelek összehasonlítását végezhetjük másfajta távolság vagy különbség meghatározó függvényekkel, az objektumok megkülönböztetésére használhatunk szegmentáló vagy klaszterező módszereket. Az átlagszámítás helyett használhatunk más matematikai eljárásokat. Összességében tehát elmondható, hogy az osztályozás eredményeinek javítására nem csak technikai, hanem számítási és módszertani lehetőségek is rendelkezésre állnak. A módszer anyagának bővítése ugyanakkor nem csak a fent említettek alapján képzelhető el. Az osztályozó módszer számára a mezőgazdasági szakterületeken belül kijelölhetünk más objektumokat is, más növényfajokat esetleg konkrét növényfajokhoz köthető betegségeket. Megvizsgálhatjuk, hogy a meghatározott objektumok felismerésére a fenti megoldások közül, melyik alkalmasabb és milyen feltételekkel. Ezekre alapozva tehát azt mondhatjuk, hogy a mezőgazdasági drónos felvételezés alkalmazása a képelemzés szempontjából nem csak sok lehetőséget rejt magában, de számos kihívással is meg kell küzdenie.

5 Felhasznált irodalom

- [1] Szabó Szabolcs (2017): Drón alkalmazásának lehetőségei gyomfelvételezésben. Szakdolgozat. BME Fotogrammetria és Térinformatika Tanszék, Budapest 2017.
- [2] <https://www.dji.com/mavic/specs>
- [3] <https://github.com/ZeevG/python-dominant-image-colour/blob/master/dominant-colour.py>
- [4] Amadou T., Sanda Mahama, Augustin S. Dossa, Pierre Gouton (2016): Choice of distance metrics for RGB color image analysis.
<https://www.ingentaconnect.com/contentone/ist/ei/2016/00002016/00000020/art00036?crawler=true&mimetype=application/pdf> Letöltés időpontja: 2018.11.23.

6 Mellékletek

kepek

class

- A. c1.png
- B. c1_nyujtott.png
- C. c2.png
- D. c2_nyujtott.png
- E. c3.png
- F. c3_nyujtott.png
- G. class_.png
- H. class_100x100.png

teszt

- I. m1.png
- J. m2.png
- K. teszt_.png
- L. teszt_100x100.png

python_kodok

- M. average_col.py
- N. class_img2.py
- O. euclidean_cat.py
- P. get_rgb.py

- Q. pixel_modszer.xlsx
- R. rgbToColour.bas